Regressão binária nos dados SAheart: análises computacionais

Davi Ferrari Hannickel e Henrique Nardi Farbelow

Outubro de 2026

Contents

Seção 1 — Dados e análise exploratória **2**

1 - a) Dimensões, tipos, codificação da resposta, valores ausentes, duplicatas e categoria de referência de famhist . . . 2

1 - b) Proporção amostral de casos . . . 4

1 - c) Descrição por grupo, gráficos, assimetria, valores extremos e associação entre adiposity e obesity . . . 4

Seção 2 — Ajuste e interpretação **7**

2 - a) Ajuste logit, convergência, estimativas, erros padrão, ICs de 95% e testes de Wald . . . 7

2 - b) Razões de chances ajustadas . . . 8

2 - d) Teste de razão de verossimilhanças para a contribuição conjunta de adiposity e obesity . . . 8

Seção 3 — Forma funcional e comparação de ligações **9**

3 - a) Ajuste com probit e cloglog, log-verossimilhança e AIC . . . 9

3 - b) Diferenças de AIC e pesos de Akaike . . . 10

3 - c) Linearidade de age e tobacco com splines naturais de 3 graus de liberdade . . . 10

3 - d) Interação entre age e famhist . . . 11

Seção 4 — Probabilidades ajustadas e incerteza **11**

4 - a) Perfil de referência, probabilidades ajustadas e suporte nos dados . . . 11

4 - b) Variância de eta0, IC na escala da ligação e transformação por gˆ-1 . . . 12

4 - c) Probabilidade ajustada em função da idade por histórico familiar, com ICs pontuais . . . 13

Seção 5 — Diagnóstico e influência **14**

5 - a) Resíduos, alavancagem, distância de Cook, DFBETAs e seleção de até três observações . . . 14

5 - b) Reajuste sem cada observação selecionada e diferença entre influência e erro de registro . . . 16

5 - c) Colinearidade e separação ou quase separação . . . 18

5 - d) Desvio residual dividido pelos graus de liberdade em dados Bernoulli . . . 19

Seção 6 — Avaliação preditiva **21**

6 - a) Validação cruzada estratificada em cinco partes e modelos comparados 21

6 - b) AUC, escore de Brier e perda logarítmica fora da amostra de treinamento 22

6 - c) Calibração, número de observações por faixa e limiar para sensibilidade e especificidade . . . 23

6 - d) Validação aninhada e otimismo de selecionar e avaliar nas mesmas partições 26

Reprodutibilidade **27**

Versões, pacotes e sementes 27

Seção 1 — Dados e análise exploratória

1 - a) Dimensões, tipos, codificação da resposta, valores ausentes, duplicatas e categoria de referência de famhist

```
data("SAheart", package = "bestglm")
dados <- SAheart

cat("Dimensões:", dim(dados), "\n")
```

```
## Dimensões: 462 10
```

```
cat("Versão do bestglm:", as.character(packageVersion("bestglm")), "\n\n")
```

```
## Versão do bestglm: 0.37.3
```

```
str(dados)
```

```
## 'data.frame':    462 obs. of  10 variables:
##  $ sbp      : int  160 144 118 170 134 132 142 114 114 132 ...
##  $ tobacco  : num  12 0.01 0.08 7.5 13.6 6.2 4.05 4.08 0 0 ...
##  $ ldl      : num  5.73 4.41 3.48 6.41 3.5 6.47 3.38 4.59 3.83 5.8 ...
##  $ adiposity: num  23.1 28.6 32.3 38 27.8 ...
##  $ famhist  : Factor w/ 2 levels "Absent","Present": 2 1 2 2 2 2 1 2 2 2 ...
##  $ typea    : int  49 55 52 51 60 62 59 62 49 69 ...
##  $ obesity  : num  25.3 28.9 29.1 32 26 ...
##  $ alcohol  : num  97.2 2.06 3.81 24.26 57.34 ...
##  $ age      : int  52 63 46 58 49 45 38 58 29 53 ...
##  $ chd      : int  1 1 0 1 1 0 0 1 0 1 ...
```

```
cat("\nValores ausentes por variável:\n")
```

```
##
## Valores ausentes por variável:
```

```r
print(colSums(is.na(dados)))
```

```
##       sbp   tobacco       ldl adiposity   famhist     typea   obesity   alcohol
##         0         0         0         0         0         0         0         0
##       age       chd
##         0         0
```

```r
cat("\nObservações duplicadas:", sum(duplicated(dados)), "\n")
```

```
##
## Observações duplicadas: 0
```

```r
cat("\nCodificação da resposta (chd):\n")
```

```
##
## Codificação da resposta (chd):
```

```r
print(table(dados$chd, useNA = "ifany"))
```

```
##
##   0   1
## 302 160
```

```r
stopifnot(all(dados$chd %in% c(0, 1)))

if (anyNA(dados)) {
  message("Removidas ", sum(!complete.cases(dados)), " linhas com ausentes.")
  dados <- dados[complete.cases(dados), ]
}

dados$famhist <- relevel(factor(dados$famhist), ref = "Absent")
dados$chd_f   <- factor(dados$chd, levels = c(0, 1), labels = c("Ausente", "Presente"))
levels(dados$famhist)
```

```
## [1] "Absent"  "Present"
```

```r
quant <- c("sbp", "tobacco", "ldl", "adiposity", "typea", "obesity", "alcohol", "age")
quant_fixas <- setdiff(quant, "age")
n <- nrow(dados)
med <- sapply(dados[quant], median)

form_ini <- chd ~ sbp + tobacco + ldl + adiposity + famhist + typea + obesity + alcohol + age

novo <- function(age, fam, base = med) {
  fixas <- as.list(base[quant_fixas])
  do.call(data.frame, c(fixas, list(age = age,
                                    famhist = factor(fam, levels = levels(dados$famhist)))))
}
```

1 - b) Proporção amostral de casos

```
n_casos <- sum(dados$chd)
p_hat <- mean(dados$chd)
ic_p <- prop.test(n_casos, n, correct = FALSE)$conf.int
tab(data.frame(n = n, casos = n_casos, controles = n - n_casos,
               prop_casos = p_hat, ic95_inf = ic_p[1], ic95_sup = ic_p[2],
               controles_por_caso = (n - n_casos) / n_casos),
    "t_proporcao", 3)
```

n	casos	controles	prop_casos	ic95_inf	ic95_sup	controles_por_caso
462	160	302	0.346	0.304	0.391	1.888

1 - c) Descrição por grupo, gráficos, assimetria, valores extremos e associação entre adiposity e obesity

```
long <- dados |>
  pivot_longer(all_of(quant), names_to = "variavel", values_to = "valor") |>
  mutate(variavel = factor(variavel, levels = quant))

desc <- long |>
  group_by(variavel, chd_f) |>
  summarise(n = n(), media = mean(valor), dp = sd(valor), min = min(valor),
            q1 = quantile(valor, .25), mediana = median(valor),
            q3 = quantile(valor, .75), max = max(valor), .groups = "drop")
tab(desc, "t_desc_grupo", 2)
```

variavel	chd_f	n	media	dp	min	q1	mediana	q3	max
sbp	Ausente	302	135.46	17.98	101.00	124.00	132.00	144.00	214.00
sbp	Presente	160	143.74	23.68	102.00	127.50	138.00	158.50	218.00
tobacco	Ausente	302	2.63	3.61	0.00	0.00	1.04	4.20	20.00
tobacco	Presente	160	5.52	5.57	0.00	1.50	4.13	8.20	31.20
ldl	Ausente	302	4.34	1.87	0.98	3.06	3.98	5.29	15.33
ldl	Presente	160	5.49	2.23	1.55	3.94	5.06	6.58	14.16
adiposity	Ausente	302	23.97	7.77	6.74	17.51	24.62	29.96	42.06
adiposity	Presente	160	28.12	7.06	9.39	23.46	28.41	33.59	42.49
typea	Ausente	302	52.37	9.52	13.00	47.00	52.50	59.00	77.00
typea	Presente	160	54.49	10.25	20.00	47.75	55.00	61.00	78.00
obesity	Ausente	302	25.74	4.09	17.75	22.60	25.57	28.06	46.58
obesity	Presente	160	26.62	4.39	14.70	23.63	26.48	28.78	45.72
alcohol	Ausente	302	15.93	23.50	0.00	0.51	6.04	22.42	145.29
alcohol	Presente	160	19.15	26.18	0.00	0.48	8.33	24.58	147.19
age	Ausente	302	38.85	14.88	15.00	27.00	40.00	50.75	64.00
age	Presente	160	50.29	10.65	17.00	42.75	53.00	59.00	64.00

```r
tf <- table(famhist = dados$famhist, chd = dados$chd_f)
tf
```

```
##          chd
## famhist   Ausente Presente
##   Absent      206       64
##   Present      96       96
```

```r
round(prop.table(tf, 1), 3)
```

```
##          chd
## famhist   Ausente Presente
##   Absent    0.763    0.237
##   Present   0.500    0.500
```

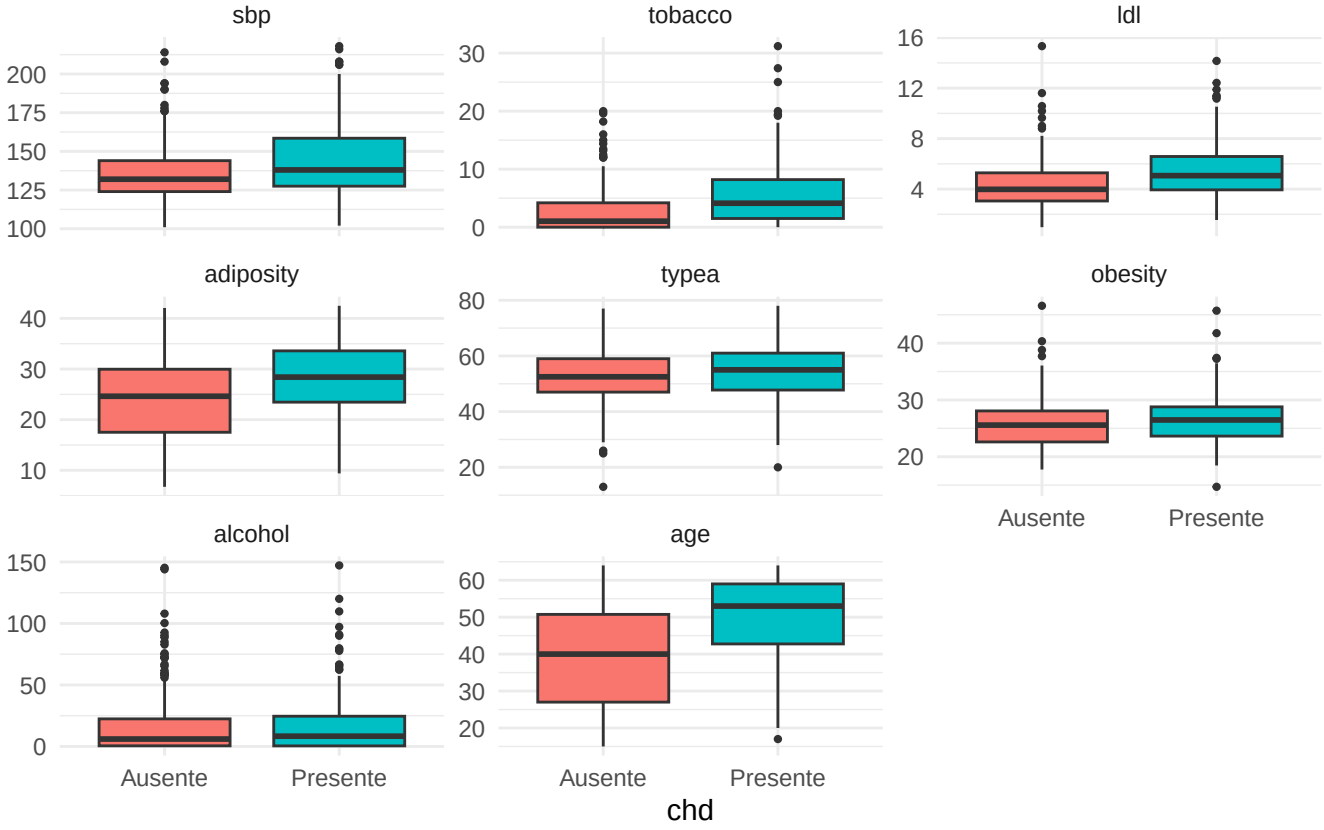
```r
skew <- function(x) { m <- mean(x); mean((x - m)^3) / mean((x - m)^2)^1.5 }
ext <- long |>
  group_by(variavel) |>
  summarise(assimetria = skew(valor),
            n_extremos_IQR = sum(valor < quantile(valor, .25) - 1.5 * IQR(valor) |
                                 valor > quantile(valor, .75) + 1.5 * IQR(valor)),
            .groups = "drop")
tab(ext[, c("variavel", "assimetria")], "t_assimetria", 2)
```

variavel	assimetria
sbp	1.18
tobacco	2.07
ldl	1.31
adiposity	-0.21
typea	-0.35
obesity	0.90
alcohol	2.31
age	-0.38

```r
ext
```

```
## # A tibble: 8 x 3
##   variavel  assimetria n_extremos_IQR
##   <fct>          <dbl>          <int>
## 1 sbp            1.18              15
## 2 tobacco        2.07              19
## 3 ldl            1.31              14
## 4 adiposity     -0.214              0
## 5 typea         -0.345              4
## 6 obesity        0.902              9
## 7 alcohol        2.31              33
## 8 age           -0.380              0
```

```
g_box <- ggplot(long, aes(chd_f, valor, fill = chd_f)) +
  geom_boxplot(show.legend = FALSE, outlier.size = .8) +
  facet_wrap(~variavel, scales = "free_y") + labs(x = "chd", y = NULL)
g_box; salvar_fig(g_box, "f_boxplots", 7, 5)
```

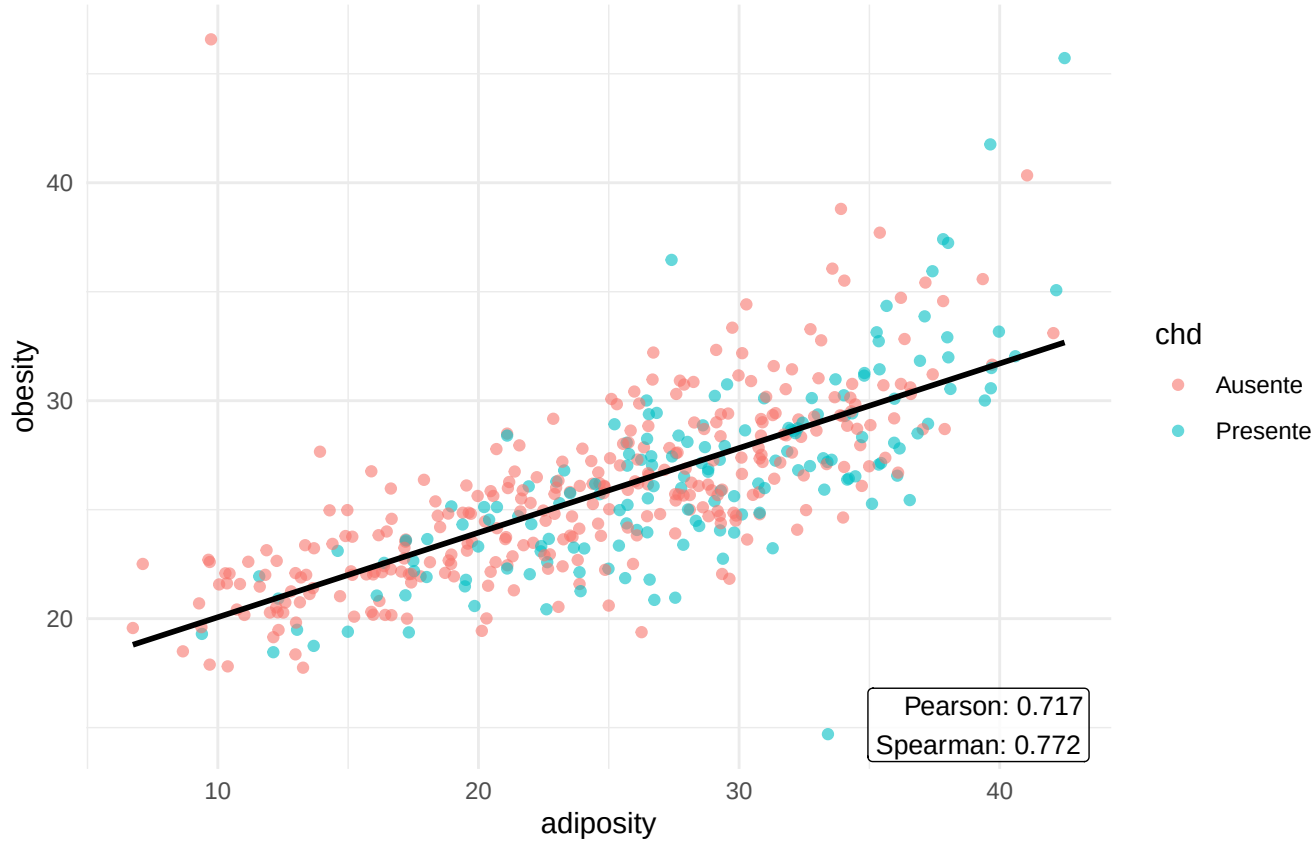



```
r_p <- round(cor(dados$adiposity, dados$obesity), 3)
r_s <- round(cor(dados$adiposity, dados$obesity, method = "spearman"), 3)
cat("Pearson:", r_p, "| Spearman:", r_s, "\n")
```

```
## Pearson: 0.717 | Spearman: 0.772
```

```
texto_cor <- paste0("Pearson: ", r_p, "\nSpearman: ", r_s)

g_ao <- ggplot(dados, aes(adiposity, obesity, colour = chd_f)) +
  geom_point(alpha = .6) +
  geom_smooth(aes(group = 1), method = "lm", se = FALSE, colour = "black") +
  annotate("label", x = Inf, y = -Inf, hjust = 1.1, vjust = -0.1,
           label = texto_cor, fill = "white", alpha = 0.8, size = 3.5) +
  labs(colour = "chd")
g_ao; salvar_fig(g_ao, "f_adiposity_obesity", 6, 4)
```



Seção 2 — Ajuste e interpretação

2 - a) Ajuste logit, convergência, estimativas, erros padrão, ICs de 95% e testes de Wald

```
loglik_bern <- function(beta, X, y, link = "logit") {
  pi <- binomial(link)$linkinv(drop(X %*% beta))
  sum(y * log(pi) + (1 - y) * log(1 - pi))
}

fit_logit   <- glm(form_ini, family = binomial("logit"),   data = dados)
fit_probit  <- glm(form_ini, family = binomial("probit"),  data = dados)
fit_cloglog <- glm(form_ini, family = binomial("cloglog"), data = dados)
fits_links <- list(logit = fit_logit, probit = fit_probit, cloglog = fit_cloglog)

X <- model.matrix(fit_logit); y <- dados$chd
cat("Convergiu:", fit_logit$converged, "| iterações:", fit_logit$iter, "\n")
```

```
## Convergiu: TRUE | iterações: 5
```

```
cat("logLik manual vs glm:", loglik_bern(coef(fit_logit), X, y), "vs", as.numeric(logLik(fit_logit)), "
```

```
## logLik manual vs glm: -236.07 vs -236.07
```

```
sm <- summary(fit_logit)$coefficients
ci <- confint.default(fit_logit)
tab_coef <- data.frame(termo = rownames(sm), estimativa = sm[, 1], ep = sm[, 2],
                       ic_inf = ci[, 1], ic_sup = ci[, 2], z = sm[, 3], p_wald = sm[, 4],
                       row.names = NULL)
tab(tab_coef, "t_coef_logit", 4)
```

termo	estimativa	ep	ic_inf	ic_sup	z	p_wald
(Intercept)	-6.1507	1.3083	-8.7149	-3.5866	-4.7015	0.0000
sbp	0.0065	0.0057	-0.0047	0.0177	1.1350	0.2564
tobacco	0.0794	0.0266	0.0272	0.1315	2.9838	0.0028
ldl	0.1739	0.0597	0.0570	0.2909	2.9152	0.0036
adiposity	0.0186	0.0293	-0.0388	0.0760	0.6346	0.5257
famhistPresent	0.9254	0.2279	0.4787	1.3720	4.0605	0.0000
typea	0.0396	0.0123	0.0154	0.0637	3.2138	0.0013
obesity	-0.0629	0.0442	-0.1496	0.0238	-1.4218	0.1551
alcohol	0.0001	0.0045	-0.0087	0.0089	0.0271	0.9784
age	0.0452	0.0121	0.0215	0.0690	3.7285	0.0002

2 - b) Razões de chances ajustadas

```
deltas <- c(sbp = 10, tobacco = 1, ldl = 1, age = 10, famhistPresent = 1)
b <- coef(fit_logit); se <- sqrt(diag(vcov(fit_logit)))
bb <- b[names(deltas)]; ss <- se[names(deltas)]
tab_or <- data.frame(
  covariavel = names(deltas), incremento = deltas,
  razão_chance = exp(deltas * bb),
  ic_inferior = exp(deltas * (bb - qnorm(.975) * ss)),
  ic_superior = exp(deltas * (bb + qnorm(.975) * ss)),
  row.names = NULL)
tab(tab_or, "t_or", 3)
```

covariavel	incremento	razão_chance	ic_inferior	ic_superior
sbp	10	1.067	0.954	1.194
tobacco	1	1.083	1.028	1.141
ldl	1	1.190	1.059	1.338
age	10	1.572	1.239	1.994
famhistPresent	1	2.523	1.614	3.943

2 - d) Teste de razão de verossimilhanças para a contribuição conjunta de adiposity e obesity

```
d1 <- drop1(fit_logit, test = "Chisq")
fit_red <- update(fit_logit, . ~ . - adiposity - obesity)
lrt_conj <- anova(fit_red, fit_logit, test = "Chisq")
print(lrt_conj)
```

```
## Analysis of Deviance Table
##
## Model 1: chd ~ sbp + tobacco + ldl + famhist + typea + alcohol + age
## Model 2: chd ~ sbp + tobacco + ldl + adiposity + famhist + typea + obesity +
##     alcohol + age
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       454     474.65
## 2       452     472.14  2   2.5112   0.2849
```

```
cat("Qui-quadrado:", round(lrt_conj$Deviance[2], 2),
    "| g.l.:", lrt_conj$Df[2],
    "| p-valor:", round(lrt_conj$`Pr(>Chi)`[2], 4), "\n")
```

```
## Qui-quadrado: 2.51 | g.l.: 2 | p-valor: 0.2849
```

```
tab_ind <- data.frame(termo = rownames(d1), p_TRV = d1$`Pr(>Chi)`, row.names = NULL) |>
  filter(termo %in% c("adiposity", "obesity")) |>
  left_join(tab_coef[, c("termo", "p_wald")], by = "termo")
tab(tab_ind, "t_lrt_individual", 4)
```

termo	p_TRV	p_wald
adiposity	0.5245	0.5257
obesity	0.1480	0.1551

Seção 3 — Forma funcional e comparação de ligações

3 - a) Ajuste com probit e cloglog, log-verossimilhança e AIC

```
tab_lig <- data.frame(
  ligacao = names(fits_links),
  n_obs = sapply(fits_links, nobs),
  logvero = sapply(fits_links, function(f) as.numeric(logLik(f))),
  AIC = sapply(fits_links, AIC),
  BIC = sapply(fits_links, BIC),
  row.names = NULL)
stopifnot(length(unique(tab_lig$n_obs)) == 1)
tab(tab_lig[, c("ligacao", "logvero", "AIC", "BIC")], "t_ligacoes", 3)
```

ligacao	logvero	AIC	BIC
logit	-236.070	492.140	533.496
probit	-235.962	491.924	533.280
cloglog	-235.486	490.972	532.328

```
tab(data.frame(termo = names(coef(fit_logit)),
               logit = coef(fit_logit), probit = coef(fit_probit), cloglog = coef(fit_cloglog),
               row.names = NULL), "t_coef_ligacoes", 4)
```

termo	logit	probit	cloglog
(Intercept)	-6.1507	-3.5702	-5.0759
sbp	0.0065	0.0038	0.0056
tobacco	0.0794	0.0482	0.0541
ldl	0.1739	0.1028	0.1327
adiposity	0.0186	0.0124	0.0183
famhistPresent	0.9254	0.5390	0.7598
typea	0.0396	0.0236	0.0283
obesity	-0.0629	-0.0402	-0.0565
alcohol	0.0001	0.0000	0.0005
age	0.0452	0.0263	0.0358

3 - b) Diferenças de AIC e pesos de Akaike

```
tab_lig$delta_AIC <- tab_lig$AIC - min(tab_lig$AIC)
tab_lig$peso_Akaike <- exp(-tab_lig$delta_AIC / 2) / sum(exp(-tab_lig$delta_AIC / 2))
tab(tab_lig[, c("ligacao", "AIC", "delta_AIC", "peso_Akaike")], "t_akaike", 4)
```

ligacao	AIC	delta_AIC	peso_Akaike
logit	492.1400	1.1681	0.2559
probit	491.9241	0.9522	0.2851
cloglog	490.9719	0.0000	0.4590

3 - c) Linearidade de age e tobacco com splines naturais de 3 graus de liberdade

```
fits_form <- list(
  linear         = fit_logit,
  spline_age     = update(fit_logit, . ~ . - age + ns(age, df = 3)),
  spline_tobacco = update(fit_logit, . ~ . - tobacco + ns(tobacco, df = 3)),
  spline_ambos   = update(fit_logit, . ~ . - age - tobacco + ns(age, df = 3) + ns(tobacco, df = 3)))

lrt_vs_linear <- function(f1) {
  d <- deviance(fit_logit) - deviance(f1)
  g <- df.residual(fit_logit) - df.residual(f1)
  c(gl = g, p_TRV = if (g > 0) round(pchisq(d, g, lower.tail = FALSE), 3) else "base")
}
tab_forma <- data.frame(
  modelo = names(fits_form),
  parametros = sapply(fits_form, function(f) length(coef(f))),
  logLik = sapply(fits_form, function(f) as.numeric(logLik(f))),
  AIC = sapply(fits_form, AIC), BIC = sapply(fits_form, BIC),
  t(sapply(fits_form, lrt_vs_linear)), row.names = NULL)
tab(tab_forma, "t_splines", 4)
```

modelo	parametros	logLik	AIC	BIC	gl	p_TRV
linear	10	-236.0700	492.1400	533.4957	0	base
spline_age	12	-235.3556	494.7111	544.3379	2	0.489
spline_tobacco	12	-233.7539	491.5078	541.1346	2	0.099
spline_ambos	14	-233.4597	494.9194	552.8173	4	0.265

3 - d) Interação entre age e famhist

```
fit_int <- update(fit_logit, . ~ . + age:famhist)
lrt_int <- anova(fit_logit, fit_int, test = "Chisq"); lrt_int
```

```
## Analysis of Deviance Table
##
## Model 1: chd ~ sbp + tobacco + ldl + adiposity + famhist + typea + obesity +
##     alcohol + age
## Model 2: chd ~ sbp + tobacco + ldl + adiposity + famhist + typea + obesity +
##     alcohol + age + famhist:age
##   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1       452     472.14
## 2       451     470.56  1   1.5796   0.2088
```

```
tab(data.frame(modelo = c("sem interação", "com interação"),
               parametros = c(length(coef(fit_logit)), length(coef(fit_int))),
               logvero = c(logLik(fit_logit), logLik(fit_int)),
               AIC = c(AIC(fit_logit), AIC(fit_int)), BIC = c(BIC(fit_logit), BIC(fit_int)),
               p_TRV = c("base", round(lrt_int$`Pr(>Chi)`[2], 3))), "t_interacao", 4)
```

modelo	parametros	logvero	AIC	BIC	p_TRV
sem interação	10	-236.0700	492.1400	533.4957	base
com interação	11	-235.2802	492.5604	538.0516	0.209

Seção 4 — Probabilidades ajustadas e incerteza

4 - a) Perfil de referência, probabilidades ajustadas e suporte nos dados

```
fit_final <- fit_logit

tab(data.frame(variavel = quant_fixas, valor_mediana = unname(med[quant_fixas])),
    "t_perfil_referencia", 2)
```

variavel	valor_mediana
sbp	134.00
tobacco	2.00
ldl	4.34

variavel	valor_mediana
adiposity	26.12
typea	53.00
obesity	25.80
alcohol	7.51

```
idades_ref <- round(quantile(dados$age, c(.25, .75)))
perfis <- expand.grid(age = unname(idades_ref), famhist = c("Absent", "Present"),
                      stringsAsFactors = FALSE)
nd <- novo(perfis$age, perfis$famhist)
res4 <- pred_link(fit_final, nd)
tab(res4[, c("age", "famhist", "prob", "lo", "hi")], "t_prob_perfis", 4)
```

age	famhist	prob	lo	hi
31	Absent	0.1190	0.0767	0.1801
55	Absent	0.2856	0.2064	0.3806
31	Present	0.2541	0.1697	0.3622
55	Present	0.5022	0.4008	0.6034

```
S <- cov(dados[quant]); mu <- colMeans(dados[quant])
suporte <- do.call(rbind, lapply(seq_len(nrow(nd)), function(i) {
  a <- nd$age[i]; fh <- as.character(nd$famhist[i]); g <- dados[dados$famhist == fh, ]
  viz <- abs(g$age - a) <= 5
  data.frame(idade = a, famhist = fh, n_no_grupo = nrow(g),
             percentil_idade_no_grupo = round(100 * mean(g$age <= a), 1),
             n_obs_a_5_anos = sum(viz), casos_nesses = sum(g$chd[viz]),
             dentro_da_amplitude = a >= min(g$age) & a <= max(g$age),
             dist_mahalanobis = mahalanobis(unlist(nd[i, quant]), mu, S),
             limite_qui2_95 = qchisq(.95, length(quant)))
}))
tab(suporte, "t_suporte", 2)
```

idade	famhist	n_no_grupo	percentil_idade_no_grupo	n_obs_a_5_anos	casos_nesses	dentro_da_amplitude	dist_mahalanobis	limite_qui2_95
31	Absent	270	33.3	55	10	TRUE	1.69	15.51
55	Absent	270	78.9	60	23	TRUE	2.10	15.51
31	Present	192	14.1	21	6	TRUE	1.69	15.51
55	Present	192	70.3	71	49	TRUE	2.10	15.51

4 - b) Variância de eta0, IC na escala da ligação e transformação por g^-1

```
tt <- delete.response(terms(fit_final))
X0 <- model.matrix(tt, model.frame(tt, nd, xlev = fit_final$xlevels))
V  <- vcov(fit_final)

var_total <- diag(X0 %*% V %*% t(X0))
var_diag  <- rowSums(sweep(X0^2, 2, diag(V), "*"))
```

```
var_cov   <- var_total - var_diag

chk <- predict(fit_final, nd, type = "link", se.fit = TRUE)
cat("Máx |diferença| nos EP em relação a predict():", signif(max(abs(sqrt(var_total) - chk$se.fit)), 3))
```

```
## Máx |diferença| nos EP em relação a predict(): 4.16e-16
```

```
tab(data.frame(age = nd$age, famhist = nd$famhist, eta = res4$eta,
               var_diagonal = var_diag, var_covariancias = var_cov,
               var_total = var_total, ep = sqrt(var_total),
               ic_eta_inf = res4$ic_eta_inf, ic_eta_sup = res4$ic_eta_sup,
               prob = res4$prob, ic_prob_inf = res4$lo, ic_prob_sup = res4$hi),
    "t_variancia_eta", 4)
```

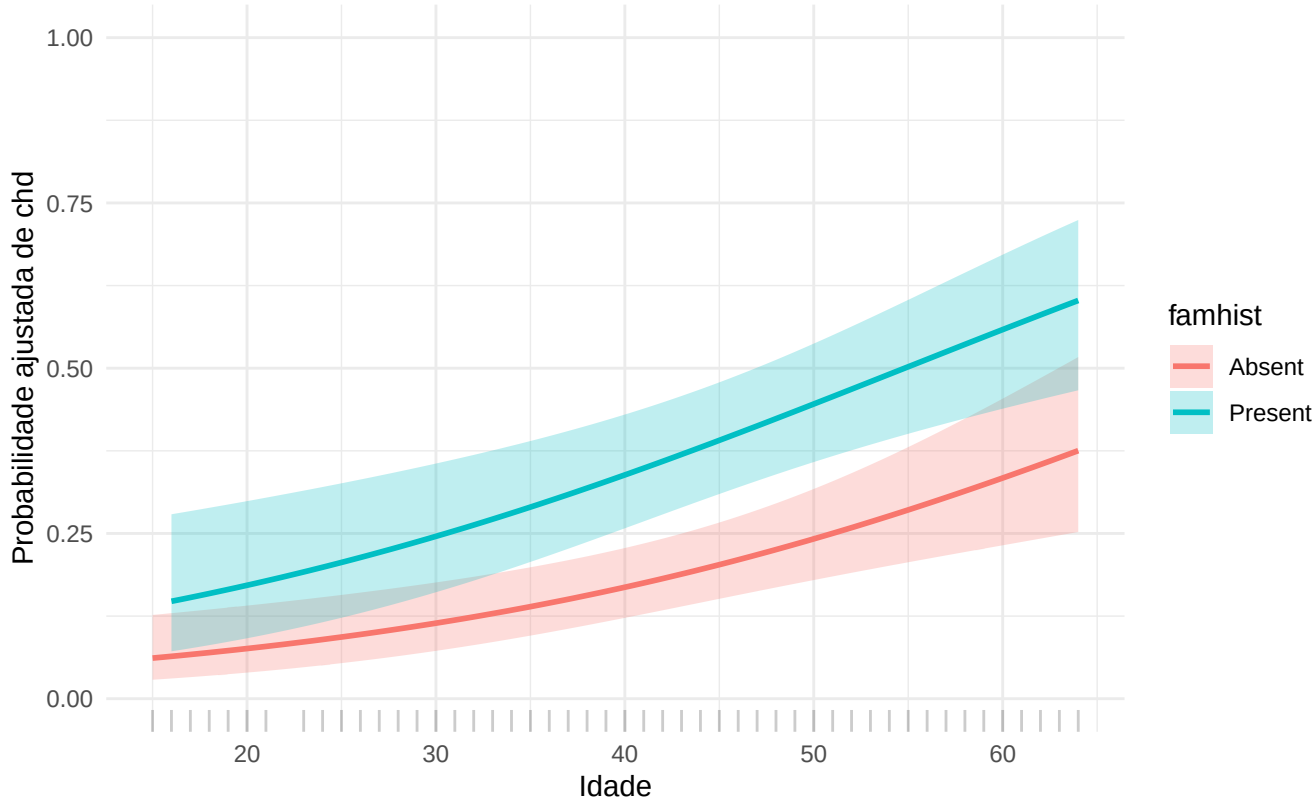
age	famhist	eta	var_diagonal	var_covariancias	var_total	ep	ic_eta_inf	ic_eta_sup	prob	ic_prob_inf	ic_prob_sup
31	Absent	-2.0022	4.8287	-4.7671	0.0616	0.2483	-2.4888	-1.5156	0.1190	0.0767	0.1801
55	Absent	-0.9168	5.1324	-5.0843	0.0481	0.2193	-1.3466	-0.4869	0.2856	0.2064	0.3806
31	Present	-1.0768	4.8807	-4.8127	0.0680	0.2607	-1.5878	-0.5658	0.2541	0.1697	0.3622
55	Present	0.0086	5.1844	-5.1404	0.0439	0.2096	-0.4023	0.4195	0.5022	0.4008	0.6034

4 - c) Probabilidade ajustada em função da idade por histórico familiar, com ICs pontuais

```
amp <- dados |> group_by(famhist) |> summarise(a0 = min(age), a1 = max(age), .groups = "drop")
grade <- do.call(rbind, lapply(seq_len(nrow(amp)), function(i)
  novo(seq(amp$a0[i], amp$a1[i], length.out = 100), as.character(amp$famhist[i]))))

pont <- pred_link(fit_final, grade)

g_prob <- ggplot(pont, aes(age, prob, colour = famhist, fill = famhist)) +
  geom_ribbon(aes(ymin = lo, ymax = hi), alpha = .25, colour = NA) +
  geom_line(linewidth = 1) +
  geom_rug(data = dados, aes(x = age, y = NULL), inherit.aes = FALSE, alpha = .2) +
  coord_cartesian(ylim = c(0, 1)) +
  labs(x = "Idade", y = "Probabilidade ajustada de chd", colour = "famhist", fill = "famhist",
       caption = "Faixa sombreada: IC 95% pontual.")
g_prob; salvar_fig(g_prob, "f_prob_idade", 7, 4.5)
```



Faixa sombreada: IC 95% pontual.

Seção 5 — Diagnóstico e influência

5 - a) Resíduos, alavancagem, distância de Cook, DFBETAs e seleção de até três observações

```
pp <- length(coef(fit_final))
dfb <- dfbetas(fit_final)
diag_df <- data.frame(
  id = seq_len(n), chd_f = dados$chd_f, ajustado = fitted(fit_final),
  r_pearson = rstandard(fit_final, type = "pearson"),
  r_dev = rstandard(fit_final, type = "deviance"),
  h = hatvalues(fit_final), cook = cooks.distance(fit_final),
  dfb_max = apply(abs(dfb), 1, max))

lim <- c(r_dev = 2, h = 2 * pp / n, cook = 4 / n, dfb_max = 2 / sqrt(n))
diag_df$n_alertas <- (abs(diag_df$r_dev) > lim["r_dev"]) + (diag_df$h > lim["h"]) +
                     (diag_df$cook > lim["cook"]) + (diag_df$dfb_max > lim["dfb_max"])
cat("Limiares:\n"); print(round(lim, 4))
```

```
## Limiares:

##   r_dev       h    cook dfb_max
##  2.0000  0.0433  0.0087  0.0930
```

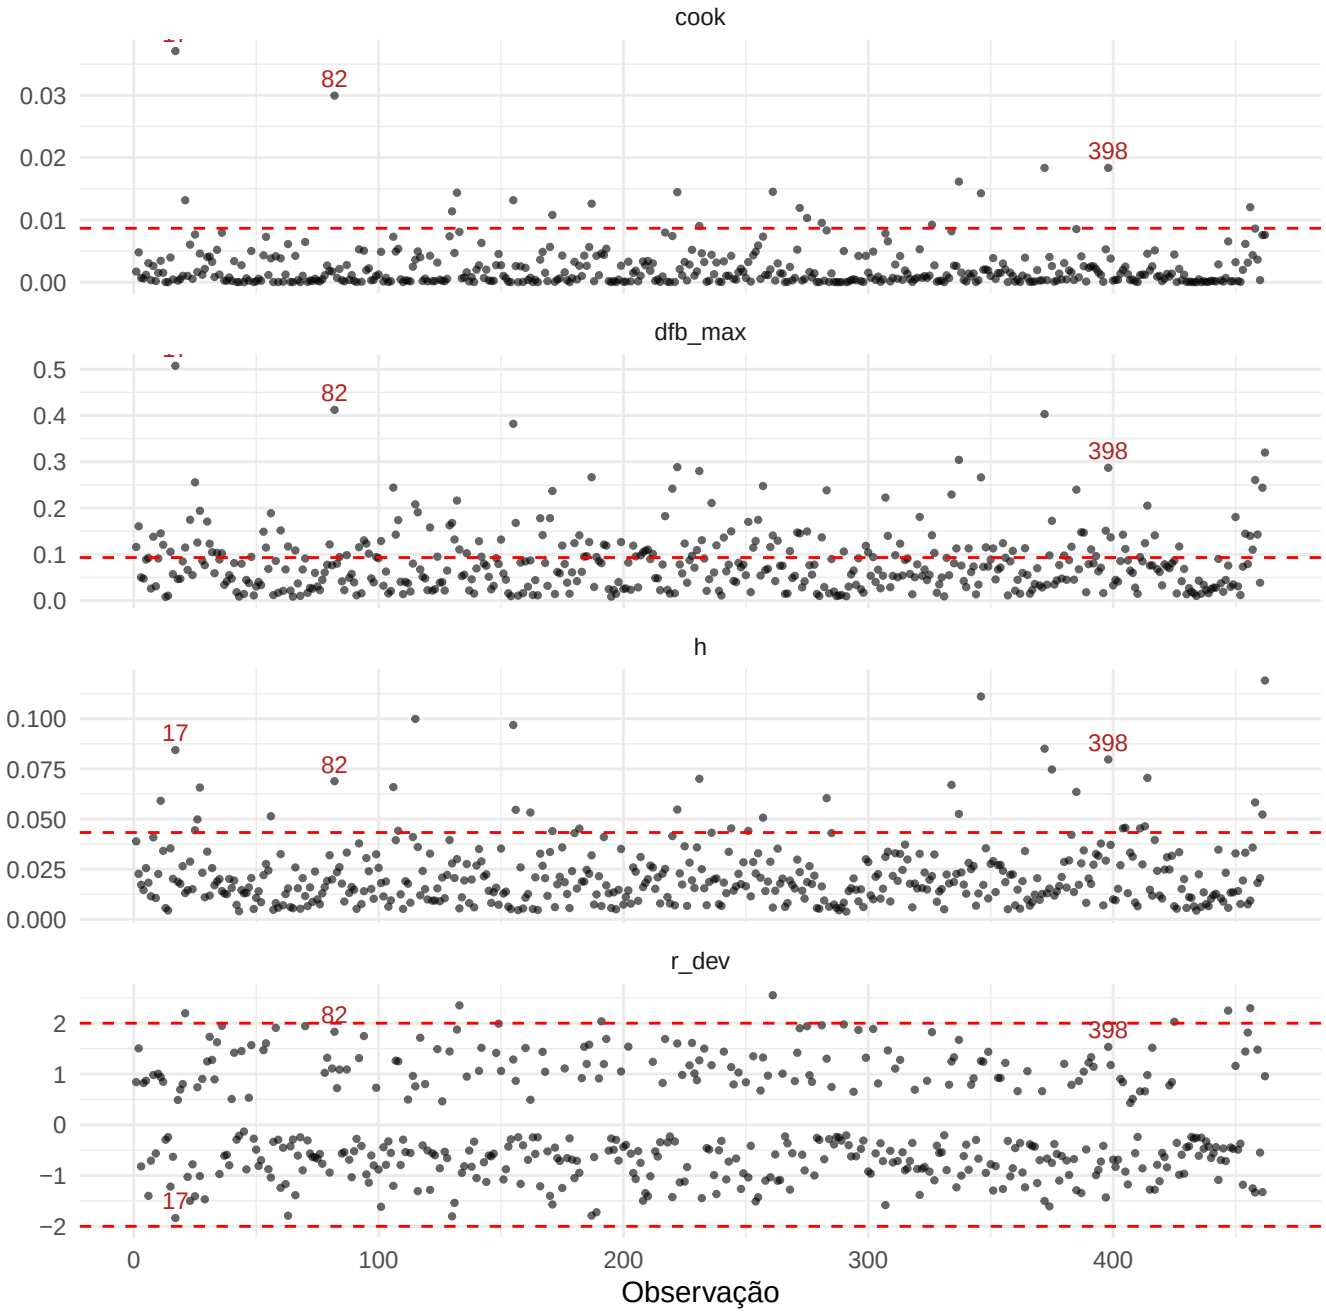
```r
cat("Observações com pelo menos 1 métrica que distoa:", sum(diag_df$n_alertas >= 1), "\n")
```

```
## Observações com pelo menos 1 métrica que distoa: 153
```

```r
sel <- diag_df |> arrange(desc(n_alertas), desc(cook)) |> head(3)
tab(sel, "t_obs_selecionadas", 4)
```

	id	chd_f	ajustado	r_pearson	r_dev	h	cook	dfb_max	n_alertas
17	17	Ausente	0.7865	-2.0059	-1.8366	0.0844	0.0371	0.5076	3
82	82	Presente	0.2097	2.0119	1.8318	0.0689	0.0300	0.4123	3
399	398	Presente	0.3391	1.4552	1.5330	0.0797	0.0183	0.2870	3

```r
diag_long <- diag_df |>
  select(id, r_dev, h, cook, dfb_max) |>
  pivot_longer(-id, names_to = "medida", values_to = "valor")
linhas <- data.frame(medida = c("r_dev", "r_dev", "h", "cook", "dfb_max"),
                     lim = c(2, -2, lim["h"], lim["cook"], lim["dfb_max"]))
g_diag <- ggplot(diag_long, aes(id, valor)) +
  geom_point(size = .8, alpha = .6) +
  geom_hline(data = linhas, aes(yintercept = lim), linetype = 2, colour = "red") +
  geom_text(data = filter(diag_long, id %in% sel$id), aes(label = id),
            vjust = -.5, size = 3, colour = "firebrick") +
  facet_wrap(~medida, scales = "free_y", ncol = 1) + labs(x = "Observação", y = NULL)
g_diag; salvar_fig(g_diag, "f_diagnosticos", 7, 8)
```



5 - b) Reajuste sem cada observação selecionada e diferença entre influência e erro de registro

```
b_full <- coef(fit_final)
p_full <- predict(fit_final, nd, type = "response")

reaj <- lapply(sel$id, function(i) {
  f <- glm(formula(fit_final), family = binomial("logit"), data = dados[-i, ])
  list(coef = coef(f), prob = predict(f, nd, type = "response"))
```

```
})
names(reaj) <- paste0("sem_obs_", sel$id)

delta_coef <- sapply(reaj, function(r) r$coef - b_full)
tab(data.frame(termo = names(b_full), estimativa_completa = b_full, round(delta_coef, 3), row.names = NU
    "t_influencia_coef", 3)
```

termo	estimativa_completa	sem_obs_17	sem_obs_82	sem_obs_398
(Intercept)	-6.151	-0.061	0.301	0.019
sbp	0.007	-0.001	0.000	-0.002
tobacco	0.079	0.001	-0.002	-0.002
ldl	0.174	0.034	0.007	0.006
adiposity	0.019	-0.006	0.005	-0.003
famhistPresent	0.925	-0.028	0.027	0.015
typea	0.040	0.001	0.001	0.001
obesity	-0.063	0.002	-0.021	0.004
alcohol	0.000	0.001	0.000	-0.001
age	0.045	0.001	-0.001	0.002

```
delta_prob <- sapply(reaj, function(r) r$prob - p_full)
tab(data.frame(age = nd$age, famhist = nd$famhist, prob_completa = p_full, delta_prob, row.names = NULL)
    "t_influencia_prob", 4)
```

age	famhist	prob_completa	sem_obs_17	sem_obs_82	sem_obs_398
31	Absent	0.1190	-0.0024	-0.0009	-0.0026
55	Absent	0.2856	0.0023	-0.0058	0.0031
31	Present	0.2541	-0.0095	0.0035	-0.0018
55	Present	0.5022	-0.0042	-0.0004	0.0076

```
valores <- dados[sel$id, c("chd", "famhist", quant)]
pct <- sapply(quant, function(v) round(100 * ecdf(dados[[v]])(dados[sel$id, v]), 1))
rownames(pct) <- sel$id
tab(cbind(id = sel$id, valores), "t_obs_valores", 2)
```

	id	chd	famhist	sbp	tobacco	ldl	adiposity	typea	obesity	alcohol	age
17	17	0	Absent	120	7.50	15.33	22.00	60	25.31	34.49	49
82	82	1	Absent	140	8.14	4.93	42.49	53	45.72	6.43	53
399	398	1	Absent	218	11.20	2.77	30.79	38	24.86	90.93	48

```
tab(cbind(id = sel$id, pct), "t_obs_percentis", 1)
```

	id	sbp	tobacco	ldl	adiposity	typea	obesity	alcohol	age
17	17	17.5	85.1	100.0	32.9	77.3	45.7	83.5	61.0
82	82	65.4	87.0	61.5	100.0	50.4	99.8	48.5	69.7
398	398	100.0	92.4	14.5	73.2	7.4	41.6	98.1	58.0

5 - c) Colinearidade e separação ou quase separação

```
vif_fin <- vif(fit_final)
tab(data.frame(termo = names(vif_fin), VIF = unname(vif_fin)), "t_vif", 2)
```

termo	VIF
sbp	1.15
tobacco	1.17
ldl	1.19
adiposity	3.45
famhist	1.02
typea	1.09
obesity	2.58
alcohol	1.07
age	1.72

```
Xp <- scale(model.matrix(fit_final)[, -1])
cat("Número de condição:", round(kappa(Xp, exact = TRUE), 2), "\n")
```

```
## Número de condição: 4.06
```

```
cat("Menor autovalor da matriz de correlação:",
    round(min(eigen(cor(model.matrix(fit_final)[, -1]))$values), 4), "\n")
```

```
## Menor autovalor da matriz de correlação: 0.1748
```

```
f_semobes <- update(fit_final, . ~ . - obesity)
tab(data.frame(modelo = c("com obesity", "sem obesity"),
               beta_adiposity = c(coef(fit_final)["adiposity"], coef(f_semobes)["adiposity"]),
               ep = c(sqrt(vcov(fit_final)["adiposity", "adiposity"]),
                      sqrt(vcov(f_semobes)["adiposity", "adiposity"]))), "t_colinearidade_efeito", 4)
```

modelo	beta_adiposity	ep
com obesity	0.0186	0.0293
sem obesity	-0.0126	0.0195

```
avisos <- character(0)
f_chk <- withCallingHandlers(
  glm(formula(fit_final), binomial, data = dados),
  warning = function(w) { avisos <<- c(avisos, conditionMessage(w)); invokeRestart("muffleWarning") })
cat("Avisos do glm:", if (length(avisos)) avisos else "nenhum", "\n")
```

```
## Avisos do glm: nenhum
```

```r
f_tight <- glm(formula(fit_final), binomial, data = dados,
               control = glm.control(epsilon = 1e-12, maxit = 200))
cat("Máx |diferença| nas estimativas com critério mais rígido:",
    signif(max(abs(coef(f_tight) - coef(fit_final))), 3), "\n")
```

```
## Máx |diferença| nas estimativas com critério mais rígido: 0
```

```r
cat("Maior erro padrão:", round(max(sqrt(diag(vcov(fit_final)))), 3),
    "| Maior |z|:", round(max(abs(summary(fit_final)$coefficients[, 3])), 2), "\n")
```

```
## Maior erro padrão: 1.308 | Maior |z|: 4.7
```

```r
cat("Probabilidades ajustadas extremas (< 1e-6 ou > 1-1e-6):",
    sum(fitted(fit_final) < 1e-6 | fitted(fit_final) > 1 - 1e-6), "\n")
```

```
## Probabilidades ajustadas extremas (< 1e-6 ou > 1-1e-6): 0
```

```r
print(table(dados$famhist, dados$chd))
```

```
##
##              0   1
##   Absent   206  64
##   Present   96  96
```

```r
if (requireNamespace("detectseparation", quietly = TRUE)) {
  print(glm(formula(fit_final), binomial, data = dados, method = detectseparation::detect_separation))
}
```

```
## Implementation: ROI | Solver: lpsolve
## Separation: FALSE
## Existence of maximum likelihood estimates
##    (Intercept)            sbp        tobacco            ldl      adiposity
##              0              0              0              0              0
## famhistPresent          typea        obesity        alcohol            age
##              0              0              0              0              0
## 0: finite value, Inf: infinity, -Inf: -infinity
```

5 - d) Desvio residual dividido pelos graus de liberdade em dados Bernoulli

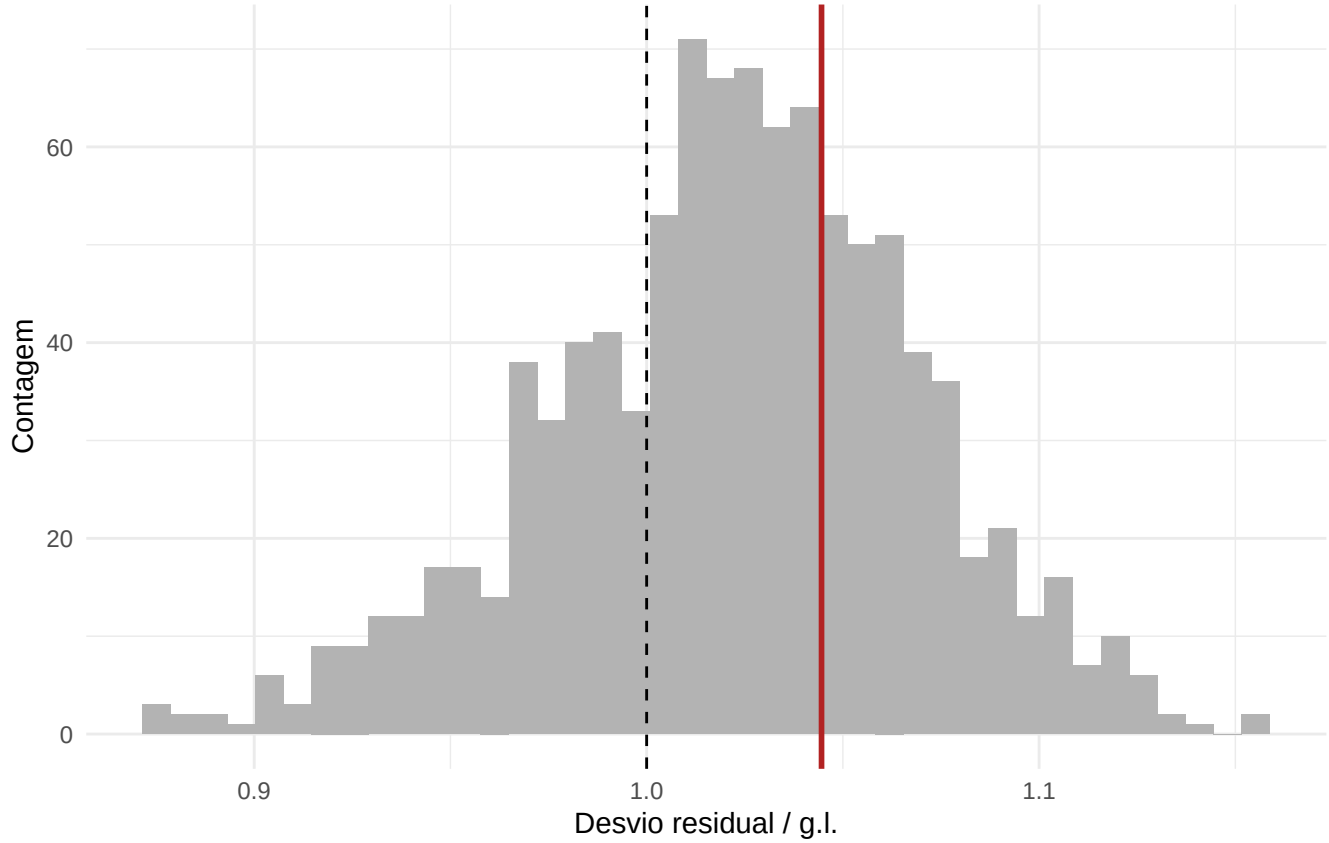
```r
dev_obs <- deviance(fit_final); gl <- df.residual(fit_final)
pear_obs <- sum(residuals(fit_final, "pearson")^2)
cat("Desvio/g.l. =", round(dev_obs / gl, 3), "| Pearson/g.l. =", round(pear_obs / gl, 3), "\n")
```

```
## Desvio/g.l. = 1.045 | Pearson/g.l. = 1
```

```r
B <- 1000
set.seed(SEED)
mu_hat <- fitted(fit_final)
sim <- replicate(B, {
  d <- dados; d$chd <- rbinom(n, 1, mu_hat)
  f <- suppressWarnings(glm(formula(fit_final), binomial, data = d))
  c(dev = deviance(f) / df.residual(f))
})
cat("Desvio/g.l. simulado sob o modelo ajustado: média =", round(mean(sim), 3),
    "| IC 95% =", round(quantile(sim, c(.025, .975)), 3), "\n")
```

```
## Desvio/g.l. simulado sob o modelo ajustado: média = 1.022 | IC 95% = 0.921 1.113
```

```r
g_sim <- ggplot(data.frame(v = sim), aes(v)) + geom_histogram(bins = 40, fill = "grey70") +
  geom_vline(xintercept = dev_obs / gl, colour = "firebrick", linewidth = 1) +
  geom_vline(xintercept = 1, linetype = 2) +
  labs(x = "Desvio residual / g.l.", y = "Contagem")
g_sim; salvar_fig(g_sim, "f_desvio_gl_simulado", 6.5, 4)
```



Seção 6 — Avaliação preditiva

6 - a) Validação cruzada estratificada em cinco partes e modelos comparados

```
make_folds <- function(y, K = 5, seed = SEED) {
  set.seed(seed)
  fold <- integer(length(y))
  for (cl in unique(y)) {
    idx <- which(y == cl)
    fold[idx] <- sample(rep_len(seq_len(K), length(idx)))
  }
  fold
}
folds <- make_folds(dados$chd, K, SEED)
cat("Semente:", SEED, "\n")
```

```
## Semente: 2026
```

```
tab(as.data.frame.matrix(table(parte = folds, chd = dados$chd)) |> tibble::rownames_to_column("parte")
      mutate(prop_casos = `1` / (`0` + `1`)), "t_particoes", 3)
```

parte	0	1	prop_casos
1	61	32	0.344
2	61	32	0.344
3	60	32	0.348
4	60	32	0.348
5	60	32	0.348

```
form_alt <- chd ~ ns(age, df = 3) + ns(tobacco, df = 3) + sbp + ldl + adiposity +
  famhist + typea + obesity + alcohol
specs <- list(
  intercepto    = list(f = chd ~ 1, link = "logit"),
  logit_inicial = list(f = form_ini, link = "logit"),
  alt_spline    = list(f = form_alt, link = "logit"))

fit_pred <- function(spec, train, test) {
  m <- suppressWarnings(glm(spec$f, family = binomial(spec$link), data = train))
  suppressWarnings(as.numeric(predict(m, newdata = test, type = "response")))
}
oof <- sapply(specs, function(s) {
  p <- numeric(n)
  for (k in seq_len(K)) {
    tr <- folds != k
    p[!tr] <- fit_pred(s, dados[tr, ], dados[!tr, ])
  }
  p
})
colnames(oof) <- names(specs)
summary(oof)
```

```
##    intercepto     logit_inicial        alt_spline
##  Min.   :0.3459   Min.   :0.003927   Min.   :0.00125
##  1st Qu.:0.3459   1st Qu.:0.144099   1st Qu.:0.13930
##  Median :0.3459   Median :0.302955   Median :0.31704
##  Mean   :0.3463   Mean   :0.340507   Mean   :0.33926
##  3rd Qu.:0.3469   3rd Qu.:0.508547   3rd Qu.:0.51875
##  Max.   :0.3469   Max.   :0.940024   Max.   :0.99820
```

6 - b) AUC, escore de Brier e perda logarítmica fora da amostra de treinamento

```
clip <- function(p) pmin(pmax(p, EPS), 1 - EPS)
auc_f <- function(y, p) as.numeric(pROC::auc(pROC::roc(y, p, levels = c(0, 1), direction = "<", quiet =
metricas <- function(y, p) {
  p2 <- clip(p)
  c(AUC = auc_f(y, p), Brier = mean((y - p)^2), LogLoss = -mean(y * log(p2) + (1 - y) * log(1 - p2)))
}
cat("Truncamento numérico das probabilidades: epsilon =", EPS, "\n")
```

```
## Truncamento numérico das probabilidades: epsilon = 1e-15
```

```
tab_pool <- data.frame(modelo = colnames(oof), t(apply(oof, 2, function(p) metricas(dados$chd, p))), ro
tab(tab_pool, "t_cv_pooled", 4)
```

modelo	AUC	Brier	LogLoss
intercepto	0.4980	0.2264	0.6451
logit_inicial	0.7672	0.1813	0.5378
alt_spline	0.7651	0.1837	0.5420

```
por_parte <- do.call(rbind, lapply(seq_len(K), function(k) {
  i <- folds == k
  do.call(rbind, lapply(colnames(oof), function(m)
    data.frame(parte = k, modelo = m, t(metricas(dados$chd[i], oof[i, m])))))
}))
resumo_partes <- por_parte |> group_by(modelo) |>
  summarise(across(c(AUC, Brier, LogLoss), list(media = mean, dp = sd)), .groups = "drop")
tab(resumo_partes, "t_cv_partes", 4)
```

modelo	AUC_media	AUC_dp	Brier_media	Brier_dp	LogLoss_media	LogLoss_dp
alt_spline	0.7694	0.0285	0.1837	0.0111	0.5419	0.0352
intercepto	0.5000	0.0000	0.2264	0.0006	0.6451	0.0013
logit_inicial	0.7712	0.0361	0.1813	0.0140	0.5377	0.0392

```
tab(por_parte, "t_cv_por_parte", 4)
```

parte	modelo	AUC	Brier	LogLoss
1	intercepto	0.5000	0.2257	0.6437
1	logit_inicial	0.7116	0.2049	0.6045
1	alt_spline	0.7234	0.2022	0.6016
2	intercepto	0.5000	0.2257	0.6437
2	logit_inicial	0.7679	0.1813	0.5368
2	alt_spline	0.7761	0.1779	0.5243
3	intercepto	0.5000	0.2268	0.6461
3	logit_inicial	0.7802	0.1764	0.5225
3	alt_spline	0.7641	0.1857	0.5443
4	intercepto	0.5000	0.2268	0.6461
4	logit_inicial	0.7911	0.1756	0.5214
4	alt_spline	0.7969	0.1752	0.5127
5	intercepto	0.5000	0.2268	0.6461
5	logit_inicial	0.8052	0.1682	0.5031
5	alt_spline	0.7865	0.1774	0.5266

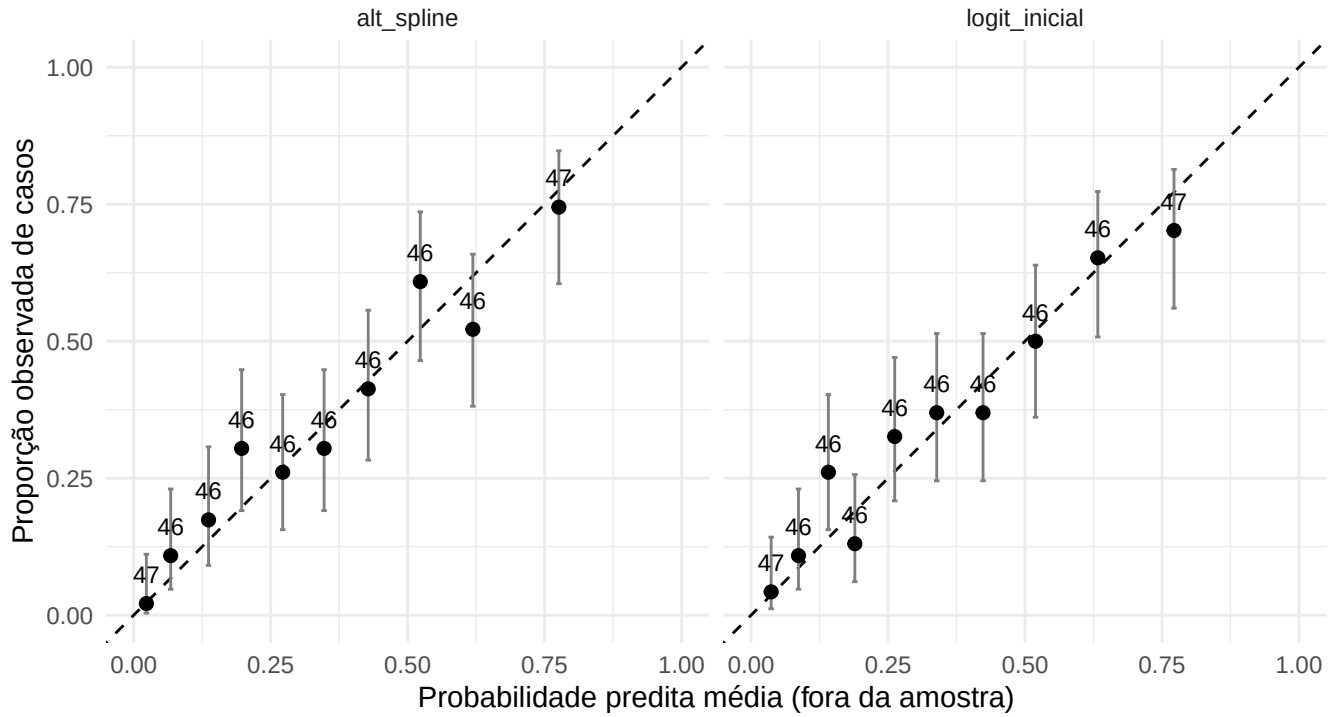
6 - c) Calibração, número de observações por faixa e limiar para sensibilidade e especificidade

```
calib_bins <- function(y, p, nb = 10) {
  br <- unique(quantile(p, seq(0, 1, length.out = nb + 1)))
  g <- cut(p, br, include.lowest = TRUE)
  d <- data.frame(y, p, g) |> group_by(g) |>
    summarise(n = n(), pred = mean(p), obs = mean(y), .groups = "drop")
  z <- 1.96
  d$lo <- (d$obs + z^2 / (2 * d$n) - z * sqrt(d$obs * (1 - d$obs) / d$n + z^2 / (4 * d$n^2))) / (1 + z^
  d$hi <- (d$obs + z^2 / (2 * d$n) + z * sqrt(d$obs * (1 - d$obs) / d$n + z^2 / (4 * d$n^2))) / (1 + z^
  d
}
cal <- do.call(rbind, lapply(c("logit_inicial", "alt_spline"), function(m)
  cbind(modelo = m, calib_bins(dados$chd, oof[, m]))))
tab(cal |> select(modelo, n, pred, obs, lo, hi), "t_calibracao", 3)
```

modelo	n	pred	obs	lo	hi
logit_inicial	47	0.037	0.043	0.012	0.142
logit_inicial	46	0.087	0.109	0.047	0.230
logit_inicial	46	0.141	0.261	0.156	0.403
logit_inicial	46	0.189	0.130	0.061	0.257
logit_inicial	46	0.262	0.326	0.209	0.470
logit_inicial	46	0.339	0.370	0.245	0.514
logit_inicial	46	0.423	0.370	0.245	0.514
logit_inicial	46	0.519	0.500	0.361	0.639
logit_inicial	46	0.633	0.652	0.508	0.773
logit_inicial	47	0.772	0.702	0.560	0.813
alt_spline	47	0.023	0.021	0.004	0.111
alt_spline	46	0.068	0.109	0.047	0.230
alt_spline	46	0.137	0.174	0.091	0.307
alt_spline	46	0.197	0.304	0.191	0.448

modelo	n	pred	obs	lo	hi
alt_spline	46	0.272	0.261	0.156	0.403
alt_spline	46	0.348	0.304	0.191	0.448
alt_spline	46	0.428	0.413	0.283	0.557
alt_spline	46	0.523	0.609	0.465	0.736
alt_spline	46	0.619	0.522	0.381	0.659
alt_spline	47	0.776	0.745	0.605	0.847

```
g_cal <- ggplot(cal, aes(pred, obs)) +
  geom_abline(linetype = 2) +
  geom_errorbar(aes(ymin = lo, ymax = hi), width = .01, colour = "grey50") +
  geom_point(size = 2) + geom_text(aes(label = n), vjust = -1.2, size = 3) +
  facet_wrap(~modelo) + coord_equal(xlim = c(0, 1), ylim = c(0, 1)) +
  labs(x = "Probabilidade predita média (fora da amostra)", y = "Proporção observada de casos",
       caption = "Rótulos: nº de observações na faixa. Barras: IC 95% de Wilson.")
g_cal; salvar_fig(g_cal, "f_calibracao", 8, 4.5)
```

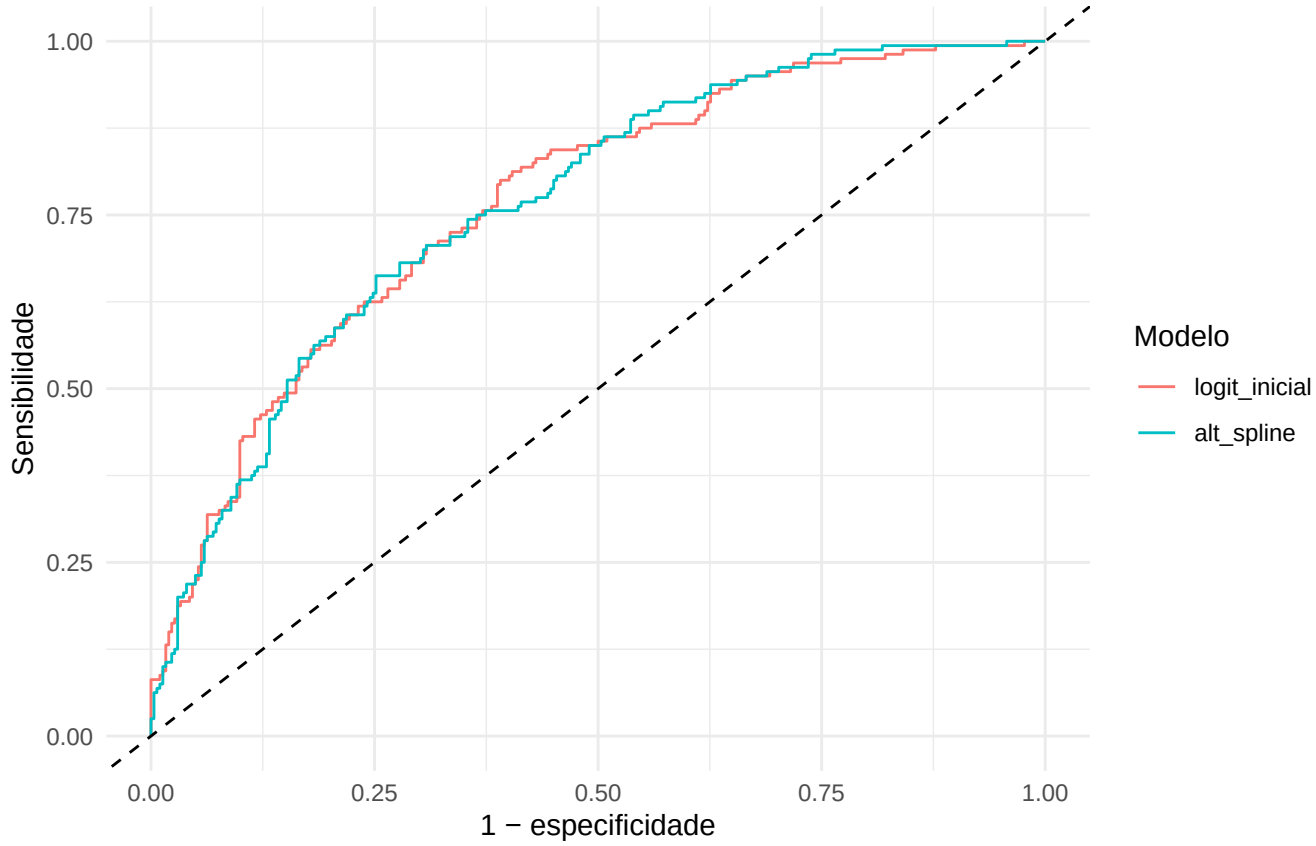


Rótulos: nº de observações na faixa. Barras: IC 95% de Wilson.

```
calib_lin <- do.call(rbind, lapply(c("logit_inicial", "alt_spline"), function(m) {
  f <- glm(dados$chd ~ qlogis(clip(oof[, m])), family = binomial)
  data.frame(modelo = m, intercepto = coef(f)[1], inclinacao = coef(f)[2], row.names = NULL)
}))
tab(calib_lin, "t_calibracao_lin", 3)
```

modelo	intercepto	inclinacao
logit_inicial	-0.033	0.868
alt_spline	-0.052	0.809

```
roc_l <- lapply(c(logit_inicial = "logit_inicial", alt_spline = "alt_spline"), function(m)
  pROC::roc(dados$chd, oof[, m], levels = c(0, 1), direction = "<", quiet = TRUE))
g_roc <- pROC::ggroc(roc_l, legacy.axes = TRUE) +
  geom_abline(linetype = 2) + labs(x = "1 - especificidade", y = "Sensibilidade", colour = "Modelo")
g_roc; salvar_fig(g_roc, "f_roc", 6, 4.5)
```




```
conf_m <- function(y, p, t) {
  pred <- as.integer(p >= t)
  tp <- sum(pred == 1 & y == 1); tn <- sum(pred == 0 & y == 0)
  fp <- sum(pred == 1 & y == 0); fn <- sum(pred == 0 & y == 1)
  c(limiar = t, sensibilidade = tp / (tp + fn), especificidade = tn / (tn + fp),
    VPP = tp / (tp + fp), VPN = tn / (tn + fn), acuracia = (tp + tn) / length(y))
}
lim_tab <- do.call(rbind, lapply(c("logit_inicial", "alt_spline"), function(m)
  do.call(rbind, lapply(c(mean(dados$chd), 0.5), function(t)
    data.frame(modelo = m, t(conf_m(dados$chd, oof[, m], t)))))))
tab(lim_tab, "t_limiar", 3)
```

modelo	limiar	sensibilidade	especificidade	VPP	VPN	acuracia
logit_inicial	0.346	0.688	0.695	0.545	0.808	0.693
logit_inicial	0.500	0.481	0.858	0.642	0.757	0.727
alt_spline	0.346	0.706	0.679	0.538	0.813	0.688
alt_spline	0.500	0.500	0.848	0.635	0.762	0.727

```
cat("Acurácia do classificador trivial (sempre 'ausente'):", round(1 - mean(dados$chd), 3), "\n")
```

```
## Acurácia do classificador trivial (sempre 'ausente'): 0.654
```

6 - d) Validação aninhada e otimismo de selecionar e avaliar nas mesmas partições

```
cand <- list(
  logit_linear   = list(f = form_ini, link = "logit"),
  probit_linear  = list(f = form_ini, link = "probit"),
  cloglog_linear = list(f = form_ini, link = "cloglog"),
  logit_spline   = list(f = form_alt, link = "logit"))

logloss_f <- function(y, p) { p <- clip(p); -mean(y * log(p) + (1 - y) * log(1 - p)) }
inner_score <- function(spec, train, K = 5, seed) {
  fi <- make_folds(train$chd, K, seed)
  p <- numeric(nrow(train))
  for (k in seq_len(K)) p[fi == k] <- fit_pred(spec, train[fi != k, ], train[fi == k, ])
  logloss_f(train$chd, p)
}

nested_p <- numeric(n); escolhas <- character(K)
for (k in seq_len(K)) {
  tr <- folds != k
  sc <- sapply(cand, inner_score, train = dados[tr, ], K = 5, seed = SEED + k)
  best <- names(which.min(sc)); escolhas[k] <- best
  nested_p[!tr] <- fit_pred(cand[[best]], dados[tr, ], dados[!tr, ])
}
cat("Modelo escolhido em cada parte externa:\n"); print(setNames(escolhas, paste0("parte", 1:K)))
```

```
## Modelo escolhido em cada parte externa:

##           parte1           parte2           parte3           parte4
##  "probit_linear"  "probit_linear" "cloglog_linear" "cloglog_linear"
##           parte5
## "cloglog_linear"
```

```
oof_cand <- sapply(cand, function(s) {
  p <- numeric(n)
  for (k in seq_len(K)) { tr <- folds != k; p[!tr] <- fit_pred(s, dados[tr, ], dados[!tr, ]) }
  p
})
ll_cand <- apply(oof_cand, 2, function(p) logloss_f(dados$chd, p))
naive_best <- min(ll_cand)
```

```r
nested_ll <- logloss_f(dados$chd, nested_p)

tab(data.frame(candidato = names(ll_cand), logloss_externo = ll_cand, row.names = NULL), "t_candidatos_a
```

candidato	logloss_externo
logit_linear	0.5378
probit_linear	0.5378
cloglog_linear	0.5372
logit_spline	0.5420

```r
tab(data.frame(avaliacao = c("Ingênua (seleciona e avalia nas mesmas partições)", "Aninhada (seleção só
               LogLoss = c(naive_best, nested_ll),
               AUC = c(auc_f(dados$chd, oof_cand[, which.min(ll_cand)]), auc_f(dados$chd, nested_p)),
               Brier = c(mean((dados$chd - oof_cand[, which.min(ll_cand)])^2), mean((dados$chd - nested_
    "t_otimismo", 4)
```

avaliacao	LogLoss	AUC	Brier
Ingênua (seleciona e avalia nas mesmas partições)	0.5372	0.7689	0.1811
Aninhada (seleção só no treinamento)	0.5395	0.7677	0.1814

```r
cat("Otimismo estimado em log-loss (aninhada - ingênua):", round(nested_ll - naive_best, 5), "\n")
```

```
## Otimismo estimado em log-loss (aninhada - ingênua): 0.00223
```

Reprodutibilidade

Versões, pacotes e sementes

```r
cat("Semente:", SEED, "\n")
```

```
## Semente: 2026
```

```r
cat("Partes da validação cruzada:", K, "| epsilon de truncamento:", EPS, "\n\n")
```

```
## Partes da validação cruzada: 5 | epsilon de truncamento: 1e-15
```

```r
pk <- c("bestglm", "ggplot2", "dplyr", "tidyr", "splines", "car", "pROC", "knitr", "tibble", "detectsepa
print(data.frame(pacote = pk,
                 versao = sapply(pk, function(p) if (requireNamespace(p, quietly = TRUE)) as.character(
                 row.names = NULL))
```

```
##              pacote versao
## 1           bestglm 0.37.3
## 2           ggplot2  4.0.3
```

```
## 3             dplyr  1.2.1
## 4             tidyr  1.3.2
## 5           splines  4.5.1
## 6               car  3.1.5
## 7              pROC 1.19.1
## 8             knitr   1.50
## 9            tibble  3.3.0
## 10 detectseparation  0.4.0
```

```
sessionInfo()
```

```
## R version 4.5.1 (2025-06-13 ucrt)
## Platform: x86_64-w64-mingw32/x64
## Running under: Windows 11 x64 (build 26200)
##
## Matrix products: default
##   LAPACK version 3.12.1
##
## locale:
## [1] LC_COLLATE=Portuguese_Brazil.utf8  LC_CTYPE=Portuguese_Brazil.utf8
## [3] LC_MONETARY=Portuguese_Brazil.utf8 LC_NUMERIC=C
## [5] LC_TIME=Portuguese_Brazil.utf8
##
## time zone: America/Sao_Paulo
## tzcode source: internal
##
## attached base packages:
## [1] splines   stats     graphics  grDevices utils     datasets  methods
## [8] base
##
## other attached packages:
## [1] knitr_1.50     pROC_1.19.1    car_3.1-5      carData_3.0-6  tidyr_1.3.2
## [6] dplyr_1.2.1    ggplot2_4.0.3  bestglm_0.37.3 leaps_3.2
##
## loaded via a namespace (and not attached):
##  [1] utf8_1.2.6              generics_0.1.4          slam_0.1-56
##  [4] shape_1.4.6.1           lattice_0.22-7          detectseparation_0.4.0
##  [7] digest_0.6.37           magrittr_2.0.4          lpSolveAPI_5.5.2.0-17.15
## [10] evaluate_1.0.5          grid_4.5.1              RColorBrewer_1.1-3
## [13] iterators_1.0.14        fastmap_1.2.0           foreach_1.5.2
## [16] glmnet_5.1              Matrix_1.7-3            backports_1.5.0
## [19] Formula_1.2-5           survival_3.8-6          ROI.plugin.lpsolve_1.0-2
## [22] mgcv_1.9-3              purrr_1.2.1             scales_1.4.0
## [25] numDeriv_2016.8-1.1     textshaping_1.0.5       codetools_0.2-20
## [28] pls_2.9-0               registry_0.5-1          abind_1.4-8
## [31] cli_3.6.5               rlang_1.1.7             ROI_1.0-2
## [34] withr_3.0.2             yaml_2.3.10             tools_4.5.1
## [37] checkmate_2.3.3         vctrs_0.7.1             R6_2.6.1
## [40] lifecycle_1.0.5         ragg_1.5.2              pkgconfig_2.0.3
## [43] grpreg_3.6.0            pillar_1.11.1           gtable_0.3.6
## [46] glue_1.8.0              Rcpp_1.1.0              systemfonts_1.3.2
## [49] xfun_0.56               tibble_3.3.0            tidyselect_1.2.1
## [52] rstudioapi_0.18.0       farver_2.1.2            nlme_3.1-168
## [55] htmltools_0.5.8.1       rmarkdown_2.32          labeling_0.4.3
```

```
## [58] compiler_4.5.1           S7_0.2.0
```