Regressão binária com múltiplas covariáveis

Associação, diagnóstico e avaliação preditiva nos dados SAheart

Formato sugerido: individual ou em duplas. Prazo sugerido: três semanas.
Entrega: relatório de até 12 páginas, excluindo referências e apêndices, e código reproduzível em arquivo separado. O enunciado não contém soluções nem códigos de ajuste.

Contexto e fonte pública

O conjunto `SAheart` contém 462 homens de uma região de alto risco de doença coronariana no Cabo Ocidental, África do Sul. A resposta indica presença de doença coronariana, e estão disponíveis nove covariáveis. O objetivo é estudar associações ajustadas e comparar modelos binários quanto ao ajuste e ao desempenho preditivo na amostra estudada.

Os dados estão disponíveis no pacote R `bestglm`, objeto `SAheart`. Consulte a documentação e importe o objeto pelo mecanismo de carregamento de dados do pacote: https://search.r-project.org/CRAN/refmans/bestglm/html/SAheart.html.

Desenho e limites. Trata-se de uma amostra retrospectiva, com aproximadamente dois controles por caso. Algumas medidas foram coletadas após tratamento ou intervenções realizadas depois do evento coronariano. Portanto, a análise não estabelece causalidade e não valida diretamente um instrumento de previsão de doença futura. As probabilidades ajustadas refletem a composição da amostra, não necessariamente o risco absoluto na população de origem.

Dicionário das variáveis

Variável	Descrição
`chd`	Resposta binária: doença coronariana, 1 = presente e 0 = ausente.
`sbp`	Pressão arterial sistólica.
`tobacco`	Consumo acumulado de tabaco, em kg.
`ldl`	Colesterol de lipoproteína de baixa densidade.
`adiposity`	Medida numérica de adiposidade.
`famhist`	Histórico familiar de doença cardíaca: `Absent` ou `Present`.
`typea`	Medida de comportamento do tipo A.
`obesity`	Medida numérica de obesidade.
`alcohol`	Consumo atual de álcool.
`age`	Idade. A documentação do pacote a descreve como “age at onset”.

Evite atribuir unidades ou interpretações mais específicas do que as documentadas. Discuta a ambiguidade temporal da variável `age` e das medidas realizadas após o evento. Identificadores de linha não devem entrar como covariáveis.

Notação e modelo inicial

Defina $Y_i = 1$ para doença coronariana e use

$$Y_i \mid \boldsymbol{x}_i \sim \text{Bernoulli}(\pi_i), \qquad \pi_i = P(Y_i = 1 \mid \boldsymbol{x}_i), \qquad g(\pi_i) = \eta_i.$$

O modelo inicial contém as nove covariáveis:

$$\begin{aligned}\eta_i = \beta_0 &+ \beta_1 \,\text{sbp}_i + \beta_2 \,\text{tobacco}_i + \beta_3 \,\text{ldl}_i + \beta_4 \,\text{adiposity}_i \\ &+ \beta_5 \,\mathbf{1}\{\text{famhist}_i = \text{Present}\} + \beta_6 \,\text{typea}_i + \beta_7 \,\text{obesity}_i \\ &+ \beta_8 \,\text{alcohol}_i + \beta_9 \,\text{age}_i.\end{aligned}$$

Considere as ligações logit, probit e complementar log-log. A expressão "sucesso" designa apenas a categoria $Y = 1$.

1. Dados e análise exploratória (1,5 ponto)

a) Confira dimensões, tipos das variáveis, codificação da resposta, valores ausentes e observações duplicadas. Defina `Absent` como referência de `famhist`. Documente o tratamento de dados ausentes, se houver.

b) Calcule a proporção amostral de casos. Explique por que ela não é automaticamente uma estimativa de prevalência populacional e por que não se exige proporção semelhante de zeros e uns para ajustar a regressão.

c) Descreva as variáveis quantitativas por grupo de resposta e apresente gráficos informativos. Investigue assimetria, valores extremos e associação entre medidas de adiposidade e obesidade.

d) Identifique possíveis dificuldades de interpretação decorrentes da amostragem retrospectiva e da coleta de covariáveis após o evento.

2. Ajuste e interpretação (2,0 pontos)

a) Escreva a log-verossimilhança Bernoulli e ajuste o modelo inicial com ligação logit. Verifique convergência e apresente estimativas, erros padrão, ICs de 95% e testes de Wald.

b) Para o modelo logístico, apresente razões de chances ajustadas e ICs para: aumento de 10 unidades em `sbp`, 1 kg em `tobacco`, 1 unidade em `ldl`, 10 anos em `age` e presença de histórico familiar.

c) Diferencie razão de chances e razão de probabilidades. Explique por que e^{β_j} não representa uma razão de chances nas ligações probit e complementar log-log.

d) Teste a contribuição conjunta de `adiposity` e `obesity` por razão de verossimilhanças. Compare a conclusão global com os testes individuais, sem adotar exclusão automática por valor-p.

3. Forma funcional e comparação de ligações (1,5 ponto)

a) Ajuste o mesmo modelo inicial com probit e complementar log-log. Compare log-verossimilhança e AIC usando exatamente as mesmas observações.

b) Calcule $\Delta_k = \mathrm{AIC}_k - \min_l \mathrm{AIC}_l$ e os pesos de Akaike. Discuta se a diferença sustenta uma preferência clara e por que os pesos não são automaticamente probabilidades posteriores.

c) Avalie a linearidade de `age` e `tobacco` na escala da ligação. Compare a forma linear com uma alternativa flexível previamente especificada, como splines naturais com três graus de liberdade. Considere o número de parâmetros na comparação.

d) Examine uma interação entre `age` e `famhist`, mantendo os efeitos principais. Compare os modelos com e sem interação e interprete a modificação do efeito, se houver. Preserve ao menos cinco covariáveis no modelo final para manter o foco multivariado da atividade.

4. Probabilidades ajustadas e incerteza (1,5 ponto)

a) Defina um perfil de referência com valores quantitativos plausíveis, documentados a partir da amostra. Calcule probabilidades ajustadas para duas idades representativas e para histórico familiar ausente e presente, mantendo as demais características fixas. Verifique se os perfis têm suporte nos dados.

b) Para um vetor de desenho $\boldsymbol{x}_0$, derive a variância aproximada de $\widehat{\eta}_0 = \boldsymbol{x}_0^\top \widehat{\boldsymbol{\beta}}$ usando a matriz completa de covariância. Construa um IC de 95% na escala da ligação e transforme os extremos por g^{-1}.

c) Apresente um gráfico da probabilidade ajustada em função da idade, separado por histórico familiar, com ICs pontuais. Explique a diferença entre bandas pontuais e simultâneas.

d) Discuta por que esses ICs não são intervalos de predição para uma resposta individual e por que as probabilidades não podem ser usadas diretamente como risco populacional sem considerar a amostragem.

5. Diagnóstico e influência (1,5 ponto)

a) Examine resíduos de Pearson e de desvio, alavancagem, distância de Cook e DFBETAs. Selecione até três observações para análise detalhada e justifique a escolha.

b) Reajuste o modelo sem cada observação selecionada, separadamente. Quantifique mudanças nos coeficientes e nas probabilidades dos perfis de referência. Diferencie influência de erro de registro.

c) Verifique colinearidade e investigue sinais de separação ou quase separação. Explique por que presença de classes desbalanceadas não equivale a separação.

d) Discuta as limitações de usar desvio residual dividido pelos graus de liberdade como diagnóstico de dispersão em dados Bernoulli sem replicação. Não aplique automaticamente a interpretação usada em contagens binomiais agrupadas.

6. Avaliação preditiva (2,0 pontos)

a) Realize validação cruzada estratificada em cinco partes. Use as mesmas partições para os modelos comparados e informe a semente. Compare o modelo inicial logístico, um modelo alternativo definido previamente e o modelo contendo apenas intercepto.

b) Com probabilidades obtidas fora da amostra de treinamento, calcule AUC, escore de Brier e perda logarítmica:

$$\text{Brier} = \frac{1}{n}\sum_i (Y_i - \widehat{\pi}_i)^2, \qquad \text{LogLoss} = -\frac{1}{n}\sum_i \{Y_i \log \widehat{\pi}_i + (1 - Y_i)\log(1 - \widehat{\pi}_i)\}.$$

Se truncar probabilidades por razões numéricas, informe o valor utilizado. Diferencie discriminação e precisão das probabilidades.

c) Apresente um gráfico de calibração com predições fora da amostra e discuta o número de observações por faixa de probabilidade. Caso apresente sensibilidade e especificidade, justifique o limiar. Não use acurácia como único critério.

d) Qualquer imputação, padronização, seleção de variáveis, escolha de ligação ou ajuste de flexibilidade baseado nos dados deve ocorrer dentro do treinamento. Se escolher o modelo pelo desempenho, use validação aninhada ou avalie candidatos fixados previamente. Explique o otimismo de selecionar e avaliar nas mesmas partições.

e) Discuta o alcance da validação: ela avalia desempenho na composição amostral disponível. Não corrige a proporção de casos imposta pela amostragem nem o uso de covariáveis medidas após o evento.

Entrega e avaliação

Organize o relatório em objetivo, dados, métodos, resultados e discussão. Apresente conclusões de associação separadamente das de predição. Identifique a versão dos dados, software, pacotes e sementes. O código deve reproduzir as tabelas e figuras. Evite listagens extensas de saída no corpo do relatório.

A pontuação total é 10,0: seções 1 a 6, respectivamente, 1,5; 2,0; 1,5; 1,5; 1,5 e 2,0 pontos. Clareza, justificativa das escolhas e reprodução integram a avaliação de cada seção. Não é necessário obter significância estatística para receber a pontuação integral.

Referências e recursos

- Rossouw, J. E. et al. (1983). Coronary risk factor screening in three rural communities. *South African Medical Journal*, 64, 430–436.
- Hastie, T., Tibshirani, R. e Friedman, J. (2009). *The Elements of Statistical Learning*. 2nd ed. Springer.
- McCullagh, P. e Nelder, J. A. (1989). *Generalized Linear Models*. 2nd ed. Chapman & Hall.
- Dados: https://search.r-project.org/CRAN/refmans/bestglm/html/SAheart.html.
- Famílias e ligações: https://stat.ethz.ch/R-manual/R-devel/library/stats/html/family.html.