Regressão Binária: Associação, Diagnóstico e Avaliação Preditiva nos Dados SAheart

Davi Ferrari Hannickel - 15447480
Henrique Nardi Farbelow - 15459250

SME0823 - Modelos de Regressão e Aprendizado Supervisionado II
Outubro de 2026
Repositório: https://github.com/hnfarbelow/Regressao-Binaria

1 Objetivo

Este trabalho tem dois propósitos distintos, que serão tratados separadamente ao longo do relatório: estudar a associação entre fatores de risco cardiovascular e a presença de doença coronariana (`chd`) e comparar modelos binários na amostra disponível.

Os dados são os do conjunto `SAheart`, do R, com 462 homens de uma região de alto risco de doença coronariana na África do Sul. A resposta é binária ($Y_i = 1$: doença presente; $Y_i = 0$: ausente) com 9 covariáveis.

Ao longo do trabalho será apresentado os seguintes itens:

(i) caracterizar os dados e discutir limitações;

(ii) ajustar o modelo com as nove covariáveis sob as ligações logit, probit e complementar log-log e interpretar as *odd-ratio*;

(iii) comparar ligações e formas do modelo usando splines naturais e a interação `age`×`famhist`);

(iv) obter as probabilidades ajustadas com intervalos de confiança para alguns perfis de referência;

(v) realizar um diagnóstico de resíduos, alavancagem e influência;

(vi) avaliar o desempenho preditivo fora da amostra.

Como algumas medidas foram obtidas após tratamento e/ou intervenções médicas, a análise não estabelece causalidade. As probabilidades ajustadas refletem a composição da amostra, e não necessariamente o risco absoluto na população de origem.

2 Dados

2.1 Fonte e descrição

Os dados são do `SAheart` do pacote `bestglm`. A amostra contém $n = 462$ homens. A Tabela 1 resume as variáveis.

Tabela 1: Dicionário das variáveis do conjunto `SAheart`.

Variável	Tipo	Descrição
`chd`	binária (0/1)	Doença coronariana: 1 = presente, 0 = ausente (resposta)
`sbp`	quantitativa	Pressão arterial sistólica
`tobacco`	quantitativa	Consumo acumulado de tabaco, em kg
`ldl`	quantitativa	Colesterol de lipoproteína de baixa densidade
`adiposity`	quantitativa	Medida numérica de adiposidade
`famhist`	categórica	Histórico familiar de doença cardíaca (`Absent`/`Present`)
`typea`	quantitativa	Medida de comportamento do tipo A
`obesity`	quantitativa	Medida numérica de obesidade
`alcohol`	quantitativa	Consumo atual de álcool
`age`	quantitativa	Idade

2.2 Verificações preliminares - 1 a)

Antes da modelagem, verificaremos as dimensões e os tipos das variáveis, a codificação da resposta binária (0 para ausente e 1 para presente), a existência de valores ausentes e a presença de duplicatas. A variável `famhist` será tratada como fator com `Absent` como referência. Se houver valores ausentes, o tratamento será feito.

2.3 Proporção de casos - 1 b)

$\hat{p} = n^{-1} \sum_i Y_i$ é a proporção amostral de casos. Essa quantidade não é automaticamente uma estimativa da prevalência populacional, pois é determinada pela amostragem e não pela ocorrência da doença na população. Por essa razão o intercepto β_0 e as probabilidades ajustadas refletem a composição amostral.

Além disso, o ajuste de uma regressão binária não exige proporção semelhante de zeros e uns. O desbalanceamento de classes afeta principalmente métricas como a acurácia, e não a validade do modelo.

2.4 Análise exploratória - 1 c)

Serão apresentados estatísticas descritivas das variáveis quantitativas por grupo de resposta, gráficos informativos, uma avaliação de assimetria e valores extremos e a associação entre `adiposity` e `obesity`.

2.5 Limitações na interpretação 1 - d)

- A proporção de casos é fixada pelo desenho amostral.
- Parte das medidas pode ter sido coletada após tratamento e/ou intervenções médicas.
- A documentação descreve a variável `age` como "*age at onset*", o que sugere idade no início da doença para os casos, já para os controles, o significado é incerto.

3 Métodos

A partir dessa seção a separação por item do enunciado do trabalho não nescessáriamente é apresentada em ordem, visando manter a estrutura pedida de objetivo, dados, métodos, resultados e discussão.

3.1 Modelo e verossimilhança

Seja $Y_i = 1$ para doença coronariana. Assumimos:

$$Y_i \mid \mathbf{x}_i \sim \text{Bernoulli}(\pi_i), \qquad \pi_i = P(Y_i = 1 \mid \mathbf{x}_i), \qquad g(\pi_i) = \eta_i = \mathbf{x}_i^\top \boldsymbol{\beta},$$

com observações independentes. O modelo inicial contém as nove covariáveis:

$$\begin{aligned}\eta_i = \beta_0 &+ \beta_1\, \texttt{sbp}_i + \beta_2\, \texttt{tobacco}_i + \beta_3\, \texttt{ldl}_i + \beta_4\, \texttt{adiposity}_i \\ &+ \beta_5\, \mathbf{1}\{\texttt{famhist}_i = \text{Present}\} + \beta_6\, \texttt{typea}_i + \beta_7\, \texttt{obesity}_i + \beta_8\, \texttt{alcohol}_i + \beta_9\, \texttt{age}_i.\end{aligned}$$

A log-verossimilhança Bernoulli é

$$\ell(\boldsymbol{\beta}) = \sum_{i=1}^{n} \Big\{ y_i \log \pi_i + (1 - y_i) \log(1 - \pi_i) \Big\}, \qquad \pi_i = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta}).$$

3.2 Funções de ligação

Serão consideradas três ligações:

$$\begin{aligned}\text{logit:} \quad & g(\pi) = \log \frac{\pi}{1-\pi}, && g^{-1}(\eta) = \frac{e^\eta}{1+e^\eta}, \\ \text{probit:} \quad & g(\pi) = \Phi^{-1}(\pi), && g^{-1}(\eta) = \Phi(\eta), \\ \text{cloglog:} \quad & g(\pi) = \log\{-\log(1-\pi)\}, && g^{-1}(\eta) = 1 - \exp\{-e^\eta\},\end{aligned}$$

em que Φ é a função de distribuição normal padrão. As ligações logit e probit são simétricas em torno de $\pi = 1/2$; a cloglog é assimétrica.

3.3 Estimação e inferência 2 - a)

Os parâmetros são estimados por máxima verossimilhança. Sob condições de regularidade, $\hat{\boldsymbol{\beta}} \overset{a}{\sim} N\big(\boldsymbol{\beta},\ \mathcal{I}(\boldsymbol{\beta})^{-1}\big)$, com $\widehat{\text{Cov}}(\hat{\boldsymbol{\beta}}) = (\mathbf{X}^\top \hat{\mathbf{W}} \mathbf{X})^{-1}$, em que $\mathbf{W} = \text{diag}\{w_i\}$ e, para ligação logit, $w_i = \pi_i(1 - \pi_i)$.

Para cada coeficiente serão apresentados erro padrão, IC de 95%, $\hat{\beta}_j \pm 1{,}96\, \widehat{\text{EP}}(\hat{\beta}_j)$, e teste de Wald $z_j = \hat{\beta}_j / \widehat{\text{EP}}(\hat{\beta}_j)$. Outros testes de hipóteses compostas (como a contribuição conjunta de `adiposity` e `obesity`) usam o TRV.

3.4 Razões de chances e razões de probabilidades 2 - b) e c)

Serão reportadas razões de chances ajustadas para: +10 unidades em `sbp`; +1 kg em `tobacco`; +1 unidade em `ldl`; +10 anos em `age`; e `famhist` Present *versus* Absent.

A razão de chances é $\dfrac{\pi_1/(1-\pi_1)}{\pi_0/(1-\pi_0)}$, enquanto a razão de probabilidades é π_1/π_0. As duas só são próximas quando o evento é muito raro. Nas ligações probit e cloglog, e^{β_j} não é uma razão de chances pois a razão de chances entre dois valores de x_j depende do ponto η em que é calculada, pois $\log\{\pi/(1-\pi)\}$ não é linear em η. Nessas ligações, β_j é interpretado na escala de $\Phi^{-1}(\pi)$ (probit) ou de $\log\{-\log(1-\pi)\}$ (cloglog).

3.5 Comparação de ligações e forma funciona 3 - a), b), c) e d)

Os três modelos (logit, probit, cloglog) serão ajustados com as mesmas observações e comparados por:

$$\mathrm{AIC}_k = -2\ell_k + 2p_k,$$

já que têm o mesmo número de parâmetros. Calcula-se $\Delta_k = \mathrm{AIC}_k - \min_l \mathrm{AIC}_l$ e os pesos de Akaike

$$w_k = \frac{\exp(-\Delta_k/2)}{\sum_l \exp(-\Delta_l/2)}.$$

A linearidade de `age` e `tobacco` na escala da ligação será avaliada comparando a forma linear com uma alternativa flexível, os splines naturais com três graus de liberdade para cada variável. A comparação usa TRV (modelos aninhados) e AIC.

Será implementado e estudado o termo `age`×`famhist`, mantendo os efeitos principais. A comparação será feita por razão de verossimilhanças e AIC também.

3.6 Probabilidades ajustadas e incerteza 4 - a), b), c) e d)

Será definido com valores quantitativos plausíveis documentados a partir da amostra alguns perfis de referência, exceto em `age` e `famhist` que terão valores diferentes com as demais características fixas. Será verificado se as combinações têm suporte nos dados para evitar extrapolação.

Para um vetor de desenho $\mathbf{x}_0$, o preditor linear estimado é $\hat\eta_0 = \mathbf{x}_0^\top \hat{\boldsymbol\beta}$ e, pela normalidade assintótica de $\hat{\boldsymbol\beta}$,

$$\widehat{\mathrm{Var}}(\hat\eta_0) = \mathbf{x}_0^\top \, \widehat{\mathrm{Cov}}(\hat{\boldsymbol\beta}) \, \mathbf{x}_0 = \sum_j x_{0j}^2 \, \widehat{\mathrm{Var}}(\hat\beta_j) + 2\sum_{j<k} x_{0j}x_{0k} \, \widehat{\mathrm{Cov}}(\hat\beta_j, \hat\beta_k),$$

O IC de 95% é construído na escala da ligação, $\hat\eta_0 \pm 1{,}96\sqrt{\widehat{\mathrm{Var}}(\hat\eta_0)}$, e seus extremos são transformados por g^{-1}, o que garante limites em $(0,1)$.

Bandas pontuais garantem cobertura de 95% apenas para cada idade isoladamente; a probabilidade de que a curva verdadeira esteja contida na banda em todas as idades ao mesmo tempo é menor que 95%. Bandas simultâneas garantem essa cobertura conjunta ao longo de todo o intervalo de idades e, por isso, são mais largas. Neste trabalho foram apresentadas apenas bandas pontuais.

Esses intervalos referem-se à incerteza em $\hat{\boldsymbol\beta}$ e não são intervalos de predição para a resposta individual. Além disso, em razão da amostragem retrospectiva, as probabilidades não são riscos populacionais sem antes uma correção que considere as frações de amostragem de casos e controles.

3.7 Diagnóstico e influência 5 - a), b), c) e d)

Serão examinados, para o modelo logístico final:

- resíduos de Pearson: $r_i^P = \dfrac{y_i - \hat\pi_i}{\sqrt{\hat\pi_i(1-\hat\pi_i)}}$.
- resíduos de *deviance*: $r_i^D = \mathrm{sinal}(y_i - \hat\pi_i)\sqrt{-2\{y_i \log\hat\pi_i + (1-y_i)\log(1-\hat\pi_i)\}}$.
- alavancagem h_{ii}, elementos diagonais de $\mathbf{W}^{1/2}\mathbf{X}(\mathbf{X}^\top\mathbf{W}\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{W}^{1/2}$.
- distância de Cook e DFBETAs, que medem a influência de cada observação sobre o ajuste global e sobre cada coeficiente.

Serão selecionadas três observações para análise detalhada, justificadas pelos critérios acima. Cada uma será removida separadamente, faremos o reajuste do modelo e a quantificação das mudanças nos coeficientes e nas probabilidades dos perfis de referência.

Influência não implica em erro de registro, pois uma observação pode ser influente por ocupar região extrema do espaço das covariáveis ou por ser um valor legítimo e incomum. A remoção só se justificaria com uma evidência de erro de registro.

Serão calculados fatores de inflação da variância (VIF), com atenção a `adiposity` e `obesity`, além das correlações entre covariáveis.

Será estudada a possibilidade da existência de separação ou quase separação. Separação ocorre quando alguma combinação linear das covariáveis classifica perfeitamente a resposta. O desbalanceamento diz respeito apenas às frequências marginais de Y.

Em dados Bernoulli sem replicação, o desvio residual dividido pelos graus de liberdade não é um diagnóstico confiável de sobredispersão uma vez que a distribuição do desvio não é aproximadamente uma qui-quadrado nessa situação, pois o desvio depende das estimativas ($\hat{\pi}_i$).

3.8 Avaliação preditiva 6 - a), b), c), d) e e)

Será realizada uma validação cruzada estratificada em cinco partes (preservando a proporção de casos em cada partição). As mesmas partições serão usadas para todos os modelos comparados.

Com probabilidades obtidas fora da amostra de treinamento, serão calculados:

$$\text{Brier} = \frac{1}{n}\sum_i (Y_i - \hat{\pi}_i)^2,$$

$$\text{LogLoss} = -\frac{1}{n}\sum_i \left\{ Y_i \log \hat{\pi}_i + (1 - Y_i)\log(1 - \hat{\pi}_i) \right\},$$

e a AUC (área sob a curva ROC). A capacidade de ordenar casos acima de controles, medida pela AUC difere da precisão das probabilidades (Brier, log-loss e calibração) pois um modelo pode discriminar bem e ter probabilidades mal calibradas.

Será apresentado o gráfico de calibração com predições fora da amostra, agrupando as probabilidades preditas em faixas e comparando-as com a frequência observada de casos em cada uma. Faixas com poucas observações têm estimativas mais instáveis.

Qualquer imputação, padronização, seleção de variáveis, escolha de ligação ou ajuste de flexibilidade baseado nos dados será feito dentro do treinamento de cada partição. Selecionar e avaliar nas mesmas partições produz um certo otimismo pois o melhor desempenho entre vários candidatos é, em média, superestimado.

A validação avalia o desempenho na composição amostral disponível. Ela não corrige a proporção de casos imposta pela amostragem nem o uso de covariáveis medidas após o evento, de modo que seus resultados não se estendem a previsão de doença futura na população.

4 Resultados

4.1 Dados e Análise Exploratória

Não há valores ausentes em nenhuma variável nem observações duplicadas. A Tabela 2 apresenta a proporção amostral de casos.

Tabela 2: Proporção amostral de casos de doença coronariana (chd)

n	Casos	Controles	Prop. Casos	IC 95% Inf	IC 95% Sup	Controles/Caso
462	160	302	0.346	0.304	0.391	1.89

A Tabela 3 descreve as variáveis quantitativas por grupo de resposta, e a Tabela 4 traz o coeficiente de assimetria amostral de cada uma. As variáveis *tobacco* e *alcohol* são as que mais se

destacam com uma forte assimetria à direita Os valores extremos aparecem como pontos isolados nos boxplots da Figura 1.

Tabela 3: Estatísticas descritivas das variáveis quantitativas por grupo de resposta

Variável	chd	n	Média	DP	Mín	Q1	Mediana	Q3	Máx
sbp	Ausente	302	135.46	17.98	101.00	124.00	132.00	144.00	214.00
sbp	Presente	160	143.74	23.68	102.00	127.50	138.00	158.50	218.00
tobacco	Ausente	302	2.63	3.61	0.00	0.00	1.04	4.20	20.00
tobacco	Presente	160	5.52	5.57	0.00	1.50	4.13	8.20	31.20
ldl	Ausente	302	4.34	1.87	0.98	3.06	3.98	5.29	15.33
ldl	Presente	160	5.49	2.23	1.55	3.94	5.06	6.58	14.16
adiposity	Ausente	302	23.97	7.77	6.74	17.51	24.62	29.96	42.06
adiposity	Presente	160	28.12	7.06	9.39	23.46	28.41	33.59	42.49
typea	Ausente	302	52.37	9.52	13.00	47.00	52.50	59.00	77.00
typea	Presente	160	54.49	10.25	20.00	47.75	55.00	61.00	78.00
obesity	Ausente	302	25.74	4.09	17.75	22.60	25.57	28.06	46.58
obesity	Presente	160	26.62	4.39	14.70	23.63	26.48	28.78	45.72
alcohol	Ausente	302	15.93	23.50	0.00	0.51	6.04	22.42	145.29
alcohol	Presente	160	19.15	26.18	0.00	0.48	8.33	24.58	147.19
age	Ausente	302	38.85	14.88	15.00	27.00	40.00	50.75	64.00
age	Presente	160	50.29	10.65	17.00	42.75	53.00	59.00	64.00

Tabela 4: Coeficiente de assimetria das variáveis quantitativas

Variável	sbp	tobacco	ldl	adiposity	typea	obesity	alcohol	age
Assimetria	1.18	2.07	1.31	-0.21	-0.35	0.90	2.31	-0.38

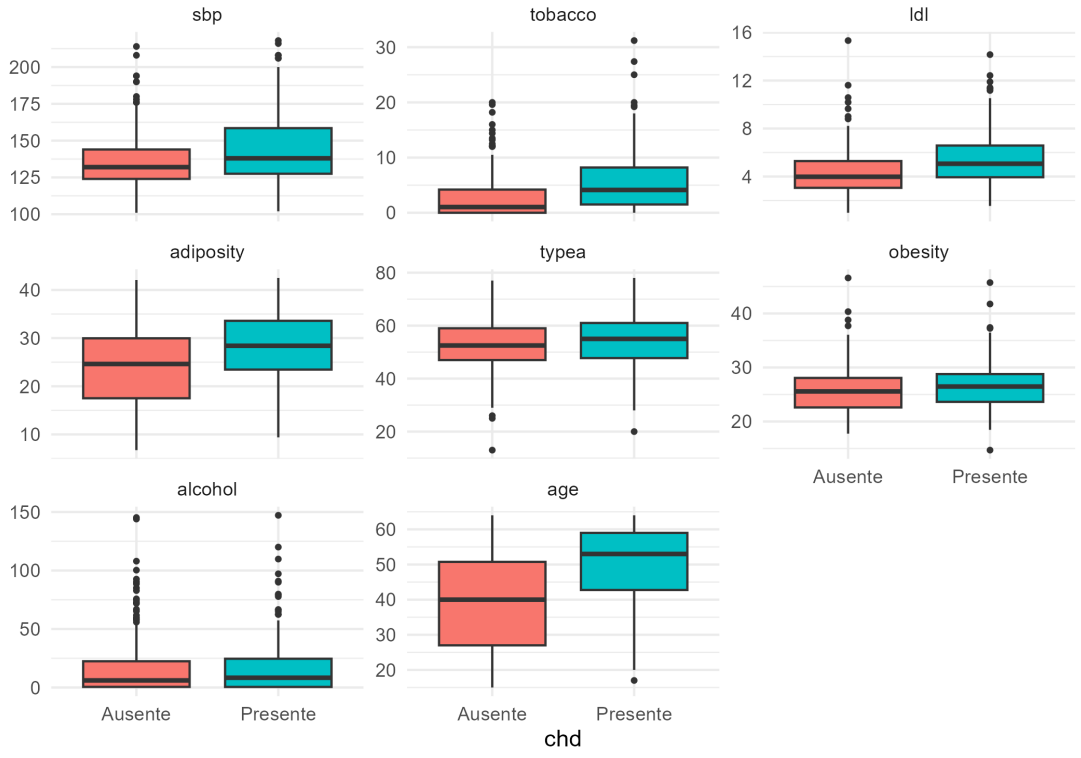


Figura 1: Boxplots das variáveis quantitativas estratificadas por desfecho (chd).

Quanto à variável categórica, a proporção de casos é de 23.7% entre os homens sem histórico familiar e de 50.0% entre os com histórico familiar.

As medidas *adiposity* e *obesity* apresentam forte associação (Pearson: 0.717; Spearman: 0.772), conforme a Figura 2.



Figura 2: Relação entre adiposidade e obesidade por grupo de desfecho.

4.2 Ajuste e Interpretação do Modelo Inicial

O modelo logístico com as nove covariáveis convergiu. A Tabela 5 apresenta estimativas, erros padrão, ICs de 95% e testes de Wald.

Tabela 5: Estimativas, erros padrão, ICs de 95% e testes de Wald para o modelo logit inicial

Termo	**Estimativa**	**Erro Padrão**	**IC Inf**	**IC Sup**	**Est. z**	**Valor-p**
(Intercepto)	-6.1507	1.3083	-8.7149	-3.5866	-4.70	<0.001
sbp	0.0065	0.0057	-0.0047	0.0177	1.14	0.2564
tobacco	0.0794	0.0266	0.0272	0.1315	2.99	0.0028
ldl	0.1739	0.0597	0.0570	0.2909	2.91	0.0036
adiposity	0.0186	0.0293	-0.0388	0.0760	0.63	0.5257
famhistPresent	0.9254	0.2279	0.4787	1.3720	4.06	<0.001
typea	0.0396	0.0123	0.0154	0.0637	3.22	0.0013
obesity	-0.0629	0.0442	-0.1496	0.0238	-1.42	0.1551
alcohol	0.0001	0.0045	-0.0087	0.0089	0.03	0.9784
age	0.0452	0.0121	0.0215	0.0690	3.74	0.0002

A Tabela 6 apresenta as razões de chances ajustadas e seus ICs de 95% para os incrementos definidos no enunciado.

Tabela 6: Razões de chances (OR) ajustadas para incrementos específicos

Covariável	Incremento	OR	IC Inf	IC Sup	Valor-p Wald
sbp	10	1.067	0.954	1.194	0.2564
tobacco	1	1.083	1.028	1.141	0.0028
ldl	1	1.190	1.059	1.338	0.0036
age	10	1.572	1.239	1.994	0.0002
famhistPresent	1	2.523	1.614	3.943	<0.001

A contribuição conjunta de *adiposity* e *obesity* foi avaliada pelo teste da razão de verossimilhanças (TRV), comparando o modelo sem as duas variáveis ao modelo completo. A estatistica $\chi^2 = 2.51$ com 2 graus de liberdade gerou o p-valor ≈ 0.2849. Sem evidências contra H_0. Também foi aplicado o TRV individualmente, tanto o TRV quanto o teste de Wald não indicaram significância estatística ao nível de 5% no modelo ajustado. Para a adiposidade, obtiveram-se $p = 0,5245$ (TRV) e $p = 0,5257$ (Wald). No caso da obesidade, os valores-p foram de $0,1480$ (TRV) e $0,1551$ (Wald).

4.3 Forma Funcional e Comparação de Ligações

A Tabela 7 compara log-verossimilhança, AIC e BIC dos modelos com ligações logit, probit e cloglog, ajustados exatamente às mesmas 462 observações.

Tabela 7: Log-verossimilhança, AIC e BIC por ligação

Ligação	Log-verossimilhança	AIC	BIC
logit	-236.070	492.140	533.496
probit	-235.962	491.924	533.280
cloglog	-235.486	490.972	532.328

A Tabela 8 apresenta as diferenças de AIC (Δ_k) e os pesos de Akaike.

Tabela 8: Diferenças de AIC e pesos de Akaike

Ligação	AIC	Δ AIC	Peso de Akaike
logit	492.1400	1.1681	0.2559
probit	491.9241	0.9522	0.2851
cloglog	490.9719	0.0000	0.4590

A Tabela 9 compara o modelo linear com alternativas que substituem *age*, *tobacco* ou ambas por splines naturais com três graus de liberdade, informando o número de parâmetros e o TRV contra o modelo linear. Nenhuma alternativa apresentou evidência de não linearidade ao nível de 5%.

Tabela 9: Comparação entre a forma linear e alternativas com splines naturais (3 g.l.)

Modelo	Parâmetros	Log-verossimilhança	AIC	BIC	g.l.	p-valor TRV
linear	10	-236.0700	492.1400	533.4957	0	base
spline_age	12	-235.3556	494.7111	544.3379	2	0.489
spline_tobacco	12	-233.7539	491.5078	541.1346	2	0.099
spline_ambos	14	-233.4597	494.9194	552.8173	4	0.265

A Tabela 10 compara os modelos com e sem a interação *age:famhist*, mantendo os efeitos principais. O TRV não indica evidência de modificação do efeito da idade pelo histórico familiar ($p = 0.209$), e o AIC e o BIC são menores no modelo sem interação. O modelo final adotado será o logístico sem interação e sem splines, com as nove covariáveis originais.

Tabela 10: Comparação entre os modelos com e sem interação *age:famhist*

Modelo	Parâmetros	Log-verossimilhança	AIC	BIC	p-valor TRV
sem interação	10	-236.0700	492.1400	533.4957	base
com interação	11	-235.2802	492.5604	538.0516	0.209

4.4 Probabilidades Ajustadas e Incerteza

O perfil de referência fixa as variáveis quantitativas, exceto *age*, em suas medianas, e varia a idade entre o primeiro e o terceiro quartis (31 e 55 anos) e o histórico familiar entre *Absent* e *Present*. Os quatro perfis têm suporte nos dados. Os ICs de 95% foram obtidos na escala da ligação, com a matriz de covariância completa, e transformados por g^{-1} (Tabela 11).

Tabela 11: Probabilidades ajustadas e ICs pontuais de 95% para os perfis de referência

Idade (age)	Hist. Familiar (famhist)	Probabilidade	IC 95% Inf	IC 95% Sup
31	Absent	0.1190	0.0767	0.1801
31	Present	0.2541	0.1697	0.3622
55	Absent	0.2856	0.2064	0.3806
55	Present	0.5022	0.4008	0.6034

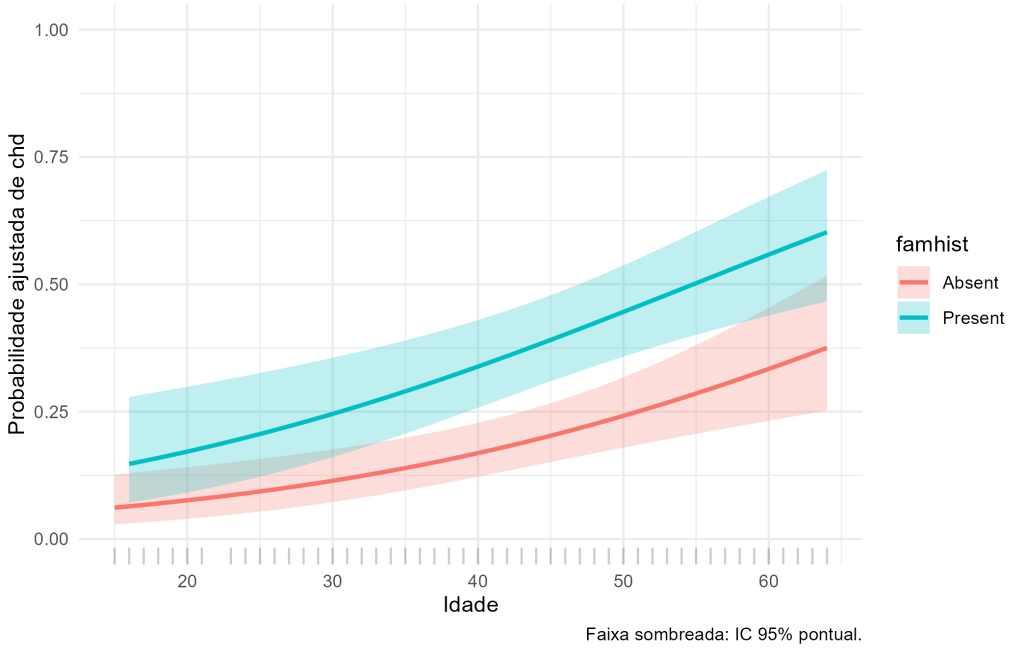


Figura 3: Probabilidade ajustada de chd em função da idade, por histórico familiar, com ICs pontuais de 95%.

4.5 Diagnóstico e Influência

Foram calculados resíduos de Pearson e de desvio padronizados, alavancagem (h), distância de Cook e DFBETAs. Os limiares usados para sinalizar observações foram $|r_{dev}| > 2$, $h > 2p/n = 0.0433$, Cook $> 4/n = 0.0087$ e DFBETA máximo $> 2/\sqrt{n} = 0.0930$. Ao todo, 153 observações ultrapassaram ao menos um limiar. Foram selecionadas as três com maior número de alertas (no caso as que ultrapassaram os quatro limiares) e, como critério de desempate, maior distância de Cook (Tabela 12).

Tabela 12: Observações selecionadas para análise detalhada

id	chd	Prob. Ajustada	Res. Pearson	Res. Desvio	Leverage (h)	Cook	DFB Máx
17	Ausente	0.7865	-2.0059	-1.8366	0.0844	0.0371	0.5076
82	Presente	0.2097	2.0119	1.8318	0.0689	0.0300	0.4123
398	Presente	0.3391	1.4552	1.5330	0.0797	0.0183	0.2870

As Tabelas 13 e 14 mostram o efeito de remover cada observação separadamente sobre os coeficientes e sobre as probabilidades dos perfis de referência. A maior mudança bruta em um coeficiente foi de 0.301 (intercepto, sem a observação 82), e entre as demais covariáveis foi de 0.034 (*ldl*, sem a observação 17). A maior mudança em probabilidade foi de 0.0095 (perfil de 31 anos com histórico familiar, sem a observação 17). Concluimos que o ajuste é sofre pouca influência dessas observações.

Tabela 13: Mudança bruta nos coeficientes ao remover cada observação

Termo	Estimativa completa	Sem obs. 17	Sem obs. 82	Sem obs. 398
(Intercept)	-6.151	-0.061	0.301	0.018
sbp	0.007	-0.001	0.000	-0.002
tobacco	0.079	0.001	-0.002	-0.002
ldl	0.174	0.034	0.007	0.006
adiposity	0.019	-0.006	0.005	-0.003
famhistPresent	0.925	-0.028	0.027	0.015
typea	0.040	0.001	0.001	0.001
obesity	-0.063	0.002	-0.021	0.004
alcohol	0.000	0.000	0.000	-0.001
age	0.045	0.001	-0.001	0.002

Tabela 14: Probabilidade ajustada completa e mudança ao remover cada observação

Idade	famhist	Prob. completa	Sem obs. 17	Sem obs. 82	Sem obs. 398
31	Absent	0.1190	-0.0024	-0.0009	-0.0026
55	Absent	0.2856	0.0023	-0.0058	0.0031
31	Present	0.2541	-0.0095	0.0035	-0.0018
55	Present	0.5022	-0.0042	-0.0004	0.0076

Os fatores de inflação da variância (VIF) foram: *sbp* 1.15, *tobacco* 1.17, *ldl* 1.19, *adiposity* 3.45, *famhist* 1.02, *typea* 1.09, *obesity* 2.58, *alcohol* 1.07 e *age* 1.72. Os maiores valores ocorrem em *adiposity* e *obesity*, o que é coerente com a correlação observada entre elas, mas nenhuma chega a atingir níveis críticos.

Não há sinais de separação ou quase separação, o `glm` não emitiu avisos, o maior erro padrão foi 1.308, o maior $|z|$ foi 4.70, nenhuma probabilidade ajustada ficou abaixo de 10^{-6} ou acima

de $1 - 10^{-6}$.

4.6 Avaliação Preditiva

A validação cruzada estratificada em $K = 5$ partes usou a semente 2026 e as mesmas partições para os três modelos comparados, o modelo logístico inicial, um modelo alternativo (splines naturais com 3 g.l. em *age* e *tobacco* e as demais covariáveis lineares) e o modelo apenas com intercepto. A Tabela 15 mostra que a proporção de casos é praticamente constante entre as partes. As probabilidades foram truncadas em $\varepsilon = 10^{-15}$ para o cálculo da perda logarítmica.

Tabela 15: Composição das partes da validação cruzada

Parte	Controles (0)	Casos (1)	Prop. casos
1	61	32	0.344
2	61	32	0.344
3	60	32	0.348
4	60	32	0.348
5	60	32	0.348

A Tabela 16 apresenta AUC, escore de Brier e perda logarítmica calculados com probabilidades fora da amostra de treinamento, como média e desvio padrão das cinco partes.

Tabela 16: Métricas preditivas fora da amostra de treinamento: média (desvio padrão) nas cinco partes

Modelo	AUC	Escore de Brier	LogLoss
Intercepto	0.5000 (0.0000)	0.2264 (0.0006)	0.6451 (0.0013)
Logit inicial	0.7712 (0.0361)	0.1813 (0.0140)	0.5377 (0.0392)
Alternativo spline	0.7694 (0.0285)	0.1837 (0.0111)	0.5419 (0.0352)

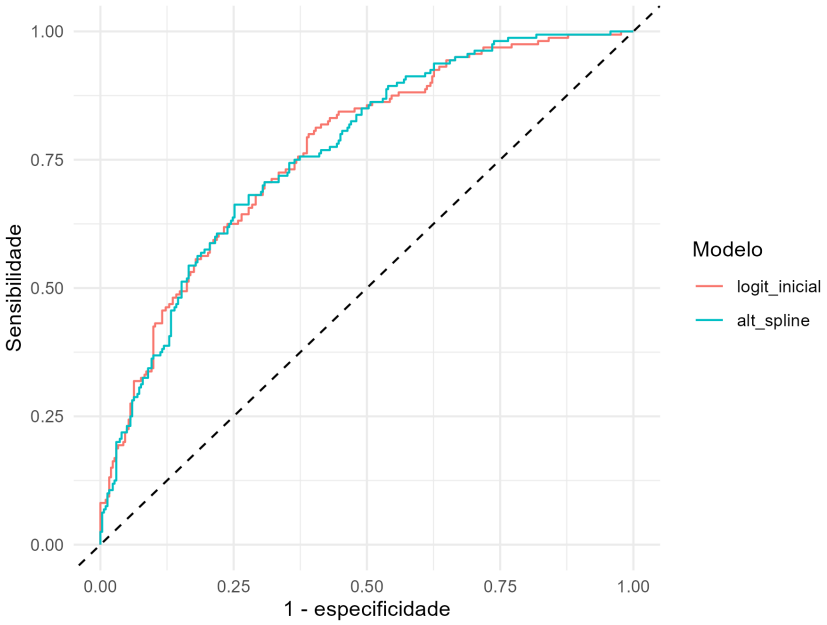


Figura 4: Curvas ROC, com predições fora da amostra, para o modelo logístico inicial e o alternativo com splines.

A Figura 5 apresenta a calibração com predições fora da amostra, em dez faixas de probabilidade preditas com $n = 46$ ou $n = 47$, com ICs de 95%. A Tabela 17 traz o intercepto e a inclinação da recalibração logística.

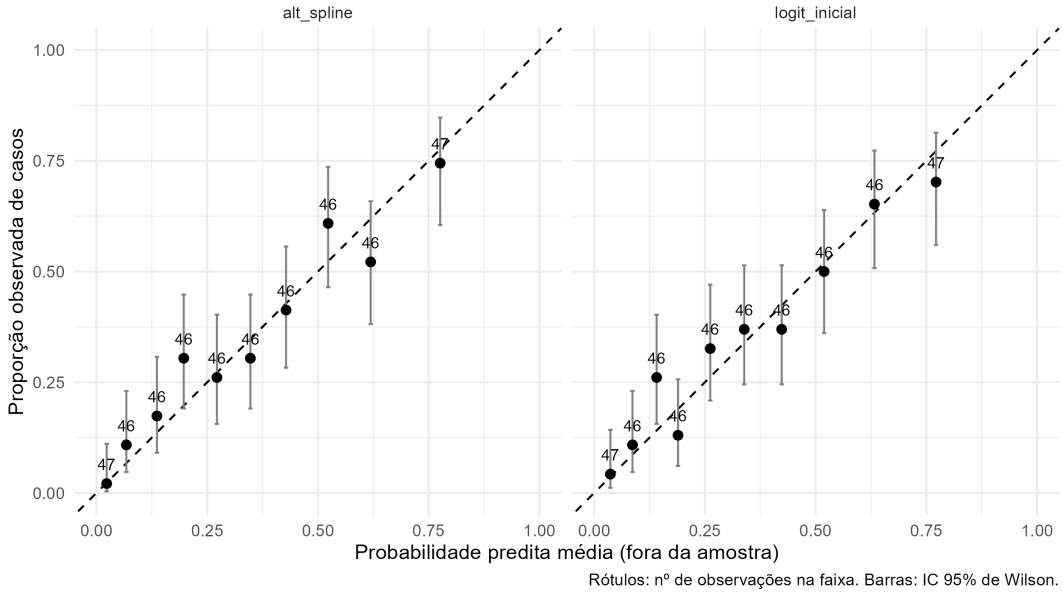


Figura 5: Calibração com predições fora da amostra e ICs de Wilson de 95%.

Tabela 17: Intercepto e inclinação de calibração

Modelo	Intercepto	Inclinação
logit_inicial	-0.033	0.868
alt_spline	-0.052	0.809

A Tabela 18 apresenta sensibilidade, especificidade, valores preditivos e acurácia em dois limiares: 0.346, que é a proporção amostral de casos, e 0.5.

Tabela 18: Desempenho de classificação por limiar (predições fora da amostra)

Modelo	Limiar	Sensib.	Especif.	VPP	VPN	Acurácia
logit_inicial	0.346	0.688	0.695	0.545	0.808	0.693
logit_inicial	0.500	0.481	0.858	0.642	0.757	0.727
alt_spline	0.346	0.706	0.679	0.538	0.813	0.688
alt_spline	0.500	0.500	0.848	0.635	0.762	0.727

Por fim, a seleção do modelo por desempenho foi avaliada por validação aninhada. Os candidatos foram logit, probit e cloglog lineares e o logit com splines, e a seleção interna usou a perda logarítmica. A Tabela 19 mostra o desempenho externo de cada candidato que é muito parecido, chamando atenção para o pior desempenho do logit com splines. A Tabela 20 compara a avaliação ingênua (seleção e avaliação nas mesmas partições) com a aninhada, e o otimismo estimado na perda logarítmica foi de 0.00223.

Tabela 19: Perda logarítmica externa dos candidatos fixados previamente

Candidato	LogLoss externo
logit_linear	0.5378
probit_linear	0.5378
cloglog_linear	0.5372
logit_spline	0.5420

Tabela 20: Avaliação do otimismo: validação ingênua versus aninhada

Estratégia de avaliação	LogLoss	AUC	Brier
Ingênua (seleciona e avalia nas mesmas partições)	0.5372	0.7689	0.1811
Aninhada (seleção só no treinamento)	0.5395	0.7677	0.1814

5 Discussão

No modelo logístico ajustado, *tobacco*, *ldl*, *famhist*, *typea* e *age* apresentaram associação estatisticamente significante (nível de 5%) com a presença de doença coronariana. As maiores razões de chances foram as de histórico familiar (OR = 2.52: a chance de doença é cerca de 2.5 vezes maior com histórico familiar, com as demais covariáveis fixas) e de idade (OR = 1.57 a cada 10 anos). Como a variável *age* é descrita como "age at onset", seu significado para os controles é incerto, então devemos ter cuidado na interpretação do efeito da idade. A ausência de significância de *adiposity* e *obesity* deve levar em conta a alta correlação entre elas, que dificulta a separação de suas contribuições. O TRV conjunto também não indicou evidência de contribuição das duas variáveis, mas ainda assim elas foram mantidas no modelo, vale destacar que uma exclusão dessas variáveis seria um resultado válido, mas não o fizemos neste trabalho. Não houve evidência de não linearidade em *age* e *tobacco* nem de uma possível interação *age:famhist*. O modelo final manteve as nove covariáveis na forma linear sem interação. Por se tratar de uma amostra retrospectiva, como discutido anteriormente, essas associações não têm interpretação causal.

As três ligações produziram ajustes muito próximos. O cloglog teve o menor AIC, mas as diferenças foram pequenas (Δ AIC ≤ 1.17) e os pesos de Akaike (0.26, 0.29 e 0.46) não indicam uma preferência clara, entretanto, vale destacar que a logit é muito mais interpretável, o que motivou sua adoção no modelo final.

As observações mais influentes (17, 82 e 398) alteraram os coeficientes em no máximo 0.301, no intercepto, e em no máximo 0.034 nas demais covariáveis, e as probabilidades dos perfis em no máximo 0.0095, indicando que não interferem significativamente na análise. Não houve sinal de separação ou quase separação, e a colinearidade ficou restrita ao par *adiposity*, *obesity*.

O desempenho fora da amostra foi moderado e semelhante entre os modelos com covariáveis, claramente superior ao modelo apenas com intercepto. Concluímos que a flexibilidade adicional dos splines não trouxe ganho preditivo. A calibração foi razoável, com inclinações de 0.87 e 0.81, indicando predições levemente extremas. Na validação aninhada, o otimismo da seleção nas mesmas partições foi pequeno. O desempenho das 3 funções de ligação são muito similares. Esses resultados refletem a composição da amostra e o uso de covariáveis medidas após o evento, e não implicam que o modelo é capaz de fazer previsões futuras.

A reprodutibilidade e as referências são encontradas no repositório.